

Supplementary Material — Ностальгический снос

Alexander Andriishin

Independent researcher; ORCID 0009-0000-4739-4017; alexander@andriishin.com

1. S1. Доказательство Теоремы 1 (адиабатическое тождество $B = K/2$ и его транзиентная реализуемость, OU)

Теорема 1 main утверждает, что в адиабатическом OU-пределе кумулятивная избыточная потеря растёт как $L_{\text{excess}}(t) = At + (K/2)\ln(\lambda t) + C + o(1)$ с логарифмическим коэффициентом, равным $K/2$, **на транзиентном окне концентрации** $t \lesssim \tau_{\text{conc}}$ (длительность всплеска коллапса приора, S1.3a–c); асимптотически при $t \gg \tau_{\text{conc}}$ установившийся коэффициент усиления g^* насыщает накопление и логарифм переходит в постоянное плато $\sim (K/2)\ln(1/g^*)$ (S1.8a) — структурная транзиентность, разбираемая в S1.4–S1.5. Вывод ведётся в линейно-гауссовом (калмановском) приближении наблюдательной модели и при явных допущениях (A1)–(A3) формулировки Теоремы 1 main; в частности шаг (S1.4) опирается на эвристическое сведение $n_{\text{eff}} \asymp \lambda s$ к классу II (A3) *на транзиентном окне*, а строгий переходный нестационарный фильтр оставлен открытым (§ 7 main). В этих рамках коэффициент $K/2$ не зависит от σ и от кривизны модели. Вывод в пять шагов: (S1.1) сведение к скалярной задаче слежения по независимым координатам; (S1.2) ошибка слежения EWMA-фильтра в OU-среде, решение Риккати, установившийся g^* и две временные шкалы (τ_f^{forget} забывания и τ_{conc} концентрации); (S1.3) разложение мгновенной избыточной потери до квадратичной формы по Фишеру; (S1.4) интегрирование на транзиентном окне, вывод коэффициента $K/2$ и переход логарифма в плато при $t \gg \tau_{\text{conc}}$; (S1.5) анализ конечно-амплитудной поправки $g(\epsilon)$ и структурная недостижимость $\hat{B} \rightarrow K/2$ как наклона; (S1.6) оптимальность флора как нижняя граница по всем архитектурам памяти (достаточность калмановского апостериора + MMSE, в линейно-гауссовом окне A1).

1.1. S1.1 Тензоризация по независимым координатам

По построению OU-параметризации (2.1) main приращения dW_{ij} независимы по (i, j) , ковариация диагональна, и процесс $\theta(t) = (\theta_{ij}(t))$ распадается на $K = k(k-1)$ независимых скалярных OU-процессов

$$d\theta_{ij} = -\lambda(\theta_{ij} - \theta_{ij}^*) dt + \sigma dW_{ij}, \quad \mathbb{E}[\theta_{ij}(t)\theta_{ij}(s)] = \sigma_0^2 e^{-\lambda|t-s|}.$$

Для идеального байесовского обучателя апостериор по $\theta(t)$ факторизуется по координатам в ведущем порядке адиабатического предела (per-bit-uniformity, [1] Замечание 5, § S2); следовательно и мгновенная избыточная потеря, и её кумулятивная сумма аддитивны:

$$L_{\text{excess}}(t) = \sum_{ij} L_{\text{excess}}^{(ij)}(t) \cdot (1 + o(1)), \quad (\text{S1.1})$$

где $L_{\text{excess}}^{(ij)}$ — избыточная потеря на одной координате. Аддитивность взаимной информации и KL-дивергенции по независимым координатам — стандартное

тождество [2] гл. 2.5; в отличие от χ^2 -меры (мультипликативной по независимости), KL/MI аддитивны, что и обеспечивает переход к множителю K в итоговом коэффициенте (та же логика, что в [1] § S1.5). Достаточно доказать скалярный результат $L_{\text{excess}}^{(ij)}(t) = at + \frac{1}{2} \ln(\lambda t) + c + o(1)$ и просуммировать по K координатам.

Координатно-свободный вывод коэффициента $K/2$ (несущий аргумент). Покомпонентная тензоризация (S1.1) удобна как иллюстрация, но значение логарифмического коэффициента $K/2$ от неё не зависит и не опирается на диагональность Фишера или независимость координат. Логарифмический член переходной концентрации (S1.4–S1.8 ниже) есть, в матричной форме, след произведения метрики Фишера на переходную апостериорную ковариацию: при концентрации апостериора с эффективным числом наблюдений n_{eff} переходная ковариация по θ есть $\Sigma_{\text{tr}} = (\mathcal{I} n_{\text{eff}})^{-1}$ (байесовская концентрация для K -мерного параметра), а мгновенный логарифмический вклад в избыточную потерю — квадратичная форма (S1.5) со следом

$$\frac{1}{2} \text{tr}(\mathcal{I} \cdot \Sigma_{\text{tr}}) = \frac{1}{2} \text{tr}(\mathcal{I} (\mathcal{I} n_{\text{eff}})^{-1}) = \frac{1}{2} \text{tr}(\text{Id}_K)/n_{\text{eff}} = \frac{K}{2 n_{\text{eff}}},$$

поскольку $\mathcal{I}(\mathcal{I})^{-1} = \text{Id}_K$ для *любой* SPD Фишер-матрицы $\mathcal{I}$ (диагональной или нет), а $\text{tr}(\text{Id}_K) = K$. Информация Фишера сокращается *тождественно* — внутри следа, без обращения к покоординатному разложению, — поэтому коэффициент $K/2$ держится и тогда, когда softmax связывает логиты одной строки (Фишер недиагонален): он зависит лишь от размерности $K = \dim \theta$, а не от структуры $\mathcal{I}$ и не от per-bit-uniformity. Подстановка $n_{\text{eff}} \asymp \lambda s$ (S1.4) и интегрирование $\int (K/2) ds/s$ дают (S1.10) напрямую. Per-bit-uniformity остаётся нужна лишь для *пола* C2 (§ S2, аддитивность вклада свежих битов), но *не* для значения $K/2$. Покоординатный вывод (S1.1)–(S1.10) ниже — частный (диагональный) случай этого следа, приводимый для наглядности.

1.2. S1.2 Ошибка слежения EWMA-фильтра и уравнение Риккати

Рассмотрим скалярную координату $\theta(t)$ (индекс ij опускаем) со скрытой ОУ-динамикой $d\theta = -\lambda\theta dt + \sigma dW$ (анкер $\theta^* = 0$ без потери общности). Наблюдения дискретны (по одному измерению на шаг $\Delta t = 1$, как в симуляциях). В линейно-гауссовом приближении вокруг текущей оценки наблюдение эквивалентно зашумлённому измерению $dy_s = \theta(s) ds + \mathcal{I}_{\text{rate}}^{-1/2} dV_s$, где V_s — стандартный винеровский процесс, а $\mathcal{I}_{\text{rate}}$ — *скорость накопления информации Фишера* (Fisher rate) размерности [Fisher]·время⁻¹: количество фишеровской информации о θ , поступающее за единицу времени. При дискретизации $\Delta t = 1$ с одним наблюдением на шаг $\mathcal{I}_{\text{rate}} = \mathcal{I}$ численно (информация на шаг равна информации на единицу времени), и ниже пишем $\mathcal{I}$ в смысле $\mathcal{I}_{\text{rate}}$; в общем случае соответствие — $\mathcal{I}_{\text{rate}} = \mathcal{I}/\Delta t$.

Оптимальный байесовский фильтр для линейно-гауссовой системы со скрытым ОУ-состоянием — стационарный фильтр Калмана–Бьюси [3, 4]. Стационарная

апостериорная дисперсия (ошибка слежения) $\Sigma_\infty := \lim_{t \rightarrow \infty} \mathbb{E}[(\hat{\theta}(t) - \theta(t))^2]$ — положительный корень непрерывно-временного алгебраического уравнения Риккати (с Fisher-rate $\mathcal{I}_{\text{rate}}$, размерности согласованы: $[\lambda\Sigma] = [\sigma^2] = [\mathcal{I}_{\text{rate}}\Sigma^2]$ — дисперсия·время⁻¹)

$$-2\lambda\Sigma_\infty + \sigma^2 - \mathcal{I}_{\text{rate}}\Sigma_\infty^2 = 0 \implies \Sigma_\infty = \frac{-2\lambda + \sqrt{4\lambda^2 + 4\mathcal{I}_{\text{rate}}\sigma^2}}{2\mathcal{I}_{\text{rate}}} = \frac{\lambda}{\mathcal{I}_{\text{rate}}} \left(\sqrt{1 + \frac{\mathcal{I}_{\text{rate}}\sigma^2}{\lambda^2}} - 1 \right). \quad (\text{S1.2})$$

Фактор 2 в члене $-2\lambda\Sigma_\infty$ — стандартный для OU (генератор $-\lambda$ действует на дисперсию с удвоением); управляющий безразмерный параметр сходимости *слежения* — это в точности $\epsilon_{\text{track}} := \mathcal{I}_{\text{rate}}\sigma^2/\lambda^2$ (определение (2.2) main), то есть отношение Fisher-rate к темпу дрейфа, взвешенное амплитудой шума. Подчеркнём отличие от $\epsilon = \sigma^2/\lambda$: ϵ — концентрация самого OU-латента, $\epsilon_{\text{track}} = \mathcal{I}_{\text{rate}}\epsilon/\lambda$ — концентрация *оценки* латента фильтром; именно ϵ_{track} , а не ϵ , контролирует разложение ниже. В адиабатическом пределе $\epsilon_{\text{track}} \ll 1$ разложение квадратного корня даёт

$$\Sigma_\infty = \frac{\lambda}{\mathcal{I}} \cdot \frac{\mathcal{I}\sigma^2}{2\lambda^2} \left(1 + O\left(\frac{\mathcal{I}\sigma^2}{\lambda^2}\right) \right) = \frac{\sigma^2}{2\lambda} (1 + O(\epsilon_{\text{track}})) = \sigma_0^2 (1 + O(\epsilon_{\text{track}})). \quad (\text{S1.3})$$

Это *стационарный* остаточный лаг фильтра: $\Sigma_\infty = \sigma_0^2(1 + O(\epsilon_{\text{track}})) \propto \sigma^2/\lambda \rightarrow 0$ в пределе OU-concentration. Эквивалентная *шкала забывания* фильтра $\tau_f^{\text{forget}} = 1/\sqrt{\lambda^2 + \mathcal{I}\sigma^2} \asymp 1/\lambda = \tau_E$ в адиабатическом пределе — то есть оптимальный фильтр забывает на шкале дрейфа среды. (*Терминологическое уточнение: ниже различаются две шкалы. Эта — шкала забывания $\tau_f^{\text{forget}} \asymp \tau_E$ — задаёт глубину памяти фильтра. Отдельная шкала τ_{conc} (время выхода на стационарный g^* , S1.3a) задаёт длительность переходного всплеска концентрации; в адиабатическом пределе они расходятся как $\tau_{\text{conc}}/\tau_f^{\text{forget}} \asymp 1/g^* = n_{\text{eff}}^* \rightarrow \infty$ (а не $\asymp 1/\epsilon_{\text{track}}$: поскольку $g^* = \frac{1}{2}\epsilon_{\text{track}}\lambda$, имеем $1/g^* = 2/(\epsilon_{\text{track}}\lambda)$, см. ниже).*)

Установившийся коэффициент усиления и флор концентрации. Стационарный фильтр Калмана имеет установившийся коэффициент усиления $g^* := \mathcal{I}_{\text{rate}}\Sigma_\infty/(1 + \mathcal{I}_{\text{rate}}\Sigma_\infty \Delta t)$, в адиабатическом пределе при $\Delta t = 1$ ведущий член

$$g^* = \mathcal{I}_{\text{rate}}\Sigma_\infty (1 + O(\epsilon_{\text{track}})) = \mathcal{I}_{\text{rate}} \cdot \frac{\sigma^2}{2\lambda} (1 + O(\epsilon_{\text{track}})) = \frac{1}{2} \epsilon_{\text{track}} \lambda (1 + O(\epsilon_{\text{track}})) \propto \sigma^2, \quad (\text{S1.3a})$$

то есть $g^* \rightarrow 0$ в адиабатическом пределе, $g^* \propto \sigma^2$ (линеен по дисперсии форсинга при фиксированных $\lambda, \mathcal{I}_{\text{rate}}$). Этот g^* задаёт *флор эффективного числа наблюдений*: установившийся фильтр взвешивает прошлое геометрически с множителем $(1 - g^*)$ за шаг, поэтому эффективное число накопленных информативных наблюдений насыщается на

$$n_{\text{eff}}^* = \frac{1 - g^*}{g^*} \approx \frac{1}{g^*} \quad (\text{точно } (1 - g^*)/g^*, \text{ ведущий член } 1/g^*), \quad (\text{S1.3b})$$

а не растёт неограниченно. Характерное время выхода на этот флор — *время концентрации*

$$\tau_{\text{conc}} \asymp n_{\text{eff}}^* \asymp 1/g^* \propto 1/\sigma^2, \quad (\text{S1.3c})$$

число шагов, за которое геометрическое окно фильтра заполняется. Принципиально: $\tau_{\text{conc}} \asymp 1/g^* \propto 1/\sigma^2$ — это *иная* шкала, чем шкала забывания $\tau_f^{\text{forget}} \asymp \tau_E = 1/\lambda$; в адиабатическом пределе их отношение есть $\tau_{\text{conc}}/\tau_E \asymp 1/g^* = n_{\text{eff}}^* \rightarrow \infty$ (физический $\tau_{\text{conc}} = 1/(\lambda g^*)$, делённый на $\tau_E = 1/\lambda$, даёт ровно $1/g^* = n_{\text{eff}}^*$ — число эффективных наблюдений). Поскольку $g^* = \frac{1}{2}\epsilon_{\text{track}}\lambda$ (S1.3a), это есть $1/g^* = 2/(\epsilon_{\text{track}}\lambda)$ — содержит явный множитель $1/\lambda$, поэтому отношение $\tau_{\text{conc}}/\tau_E$ есть $1/g^* = n_{\text{eff}}^*$, а не $1/\epsilon_{\text{track}}$. Именно τ_{conc} , а не τ_E , ограничивает окно логарифмического роста (S1.4), и его верхняя граница в адиабатическом времени есть $\lambda\tau_{\text{conc}} \asymp 1/g^* = n_{\text{eff}}^*$.

Физическое происхождение адиабатической границы $1/\sigma^2$. Верхняя граница адиабатического окна $t \ll 1/\sigma^2$ имеет прямой физический смысл: $1/\sigma^2$ — характерное время диффузионного ухода ОУ-латента на $O(1)$. За время t накопленная дисперсия чисто диффузионной части ОУ-приращения есть $\sigma^2 t$; при $t \sim 1/\sigma^2$ она достигает $O(1)$, латент успевает сместиться на масштаб самой переменной, и softmax-линеаризация (A1) вокруг текущей оценки теряет силу (точка линеаризации уходит из окрестности, в которой остаток ЕКФ/Лаплас-приближения контролируем). Поэтому $t \ll 1/\sigma^2$ — не техническое, а физическое ограничение области применимости линейно-гауссова приближения.

Почему окно не открывается адиабатическим пределом (точная формулировка неразделимости). Прежняя формулировка — « τ_{conc} и потолок $1/\sigma^2$ оба $\propto 1/\sigma^2$, потому не разделяются» — *физически неполна*: само совпадение степеней σ не влечёт неразделимости, ибо две величины, обе $\propto 1/\sigma^2$, могут иметь любое постоянное отношение. Корректный аргумент — через *ширину лог-окна* и её σ -инвариантность. Доступное лог-несущее окно есть $[t_{\min}, t_{\max}]$ с нижней границей $t_{\min} \asymp$ несколько $\tau_{\text{conc}} \asymp 1/g^*$ (логарифм жив лишь после выхода всплеска концентрации) и верхней $t_{\max} \asymp c_0/\sigma^2$ (адиабатический потолок). Его *логарифмическая ширина* (отношение границ)

$$W = \frac{t_{\max}}{t_{\min}} \asymp \frac{c_0/\sigma^2}{1/g^*} = c_0 \frac{g^*}{\sigma^2} \asymp \frac{\mathcal{I}_{\text{rate}}}{\lambda} = \frac{1}{\lambda r}$$

(подставлено $g^* = \frac{1}{2}\mathcal{I}_{\text{rate}}\sigma^2/\lambda$ из (S1.3a), σ^2 сокращается; $r = 1/\mathcal{I}_{\text{rate}}$ — шум наблюдения). Решающее: **ширина окна $W \asymp 1/(\lambda r)$ σ -инвариантна** — σ из неё ушла. Поэтому адиабатический предел $\sigma \rightarrow 0$ ($\epsilon_{\text{track}} \rightarrow 0$) *не открывает* лог-окно: и нижняя граница $\tau_{\text{conc}} \propto 1/\sigma^2$, и верхняя $1/\sigma^2$ растягиваются *в одинаковой пропорции*, отношение остаётся фиксированным $\asymp 1/(\lambda r)$. Это и есть подлинная причина неразделимости, и она *рефутуирует* рабочую гипотезу

(«толкнуть $\epsilon_{\text{track}} \rightarrow 0$ — окно раскроется»): уменьшение σ не трогает W . Расширить W можно лишь увеличив Fisher-rate на корреляционный интервал среды, $\mathcal{I}_{\text{rate}}/\lambda = 1/(\lambda r) \rightarrow \infty$ (бесконечно точное наблюдение $r \rightarrow 0$ либо $\lambda \rightarrow 0$ быстрее $\mathcal{I}_{\text{rate}}$). Но это *выводит из медленно-дрейфового (адиабатического) режима*: $\mathcal{I}_{\text{rate}}/\lambda \rightarrow \infty$ означает $\epsilon_{\text{track}} = \mathcal{I}_{\text{rate}}\sigma^2/\lambda^2 = (\mathcal{I}_{\text{rate}}/\lambda)(\sigma^2/\lambda)$ перестаёт быть малым при фиксированной концентрации латента, нарушая условие slow-driving $\lambda\tau_{\text{relax}} \ll 1$ и квазистационарность θ , на которых стоят (A1) и весь вывод. Итог: неразделимость лог-несущего и асимптотического окон — *следствие адиабатического ограничения* (фиксированной Fisher-rate на корреляционный интервал), а не арифметического совпадения степеней σ ; в любом режиме, где (A1) и квазистационарность верны, $W \asymp 1/(\lambda r) = O(1)$ относительно σ , и лог-окно не раскрывается. Это ключ к структурной недостижимости S1.5.

Помимо стационарной части, фильтр имеет *переходную* компоненту: при старте из априорной неопределённости апостериорная дисперсия $\Sigma(t)$ убывает к Σ_∞ . Для медленного дрейфа релевантная переходная дисперсия контролируется накоплением *информативных* наблюдений. **В транзиентном режиме концентрации** ($s \lesssim \tau_{\text{conc}}$, до выхода на установившийся g^*) наблюдения, разнесённые более чем на τ_E , декоррелируют (ковариация θ затухает как $e^{-\lambda|t-s|}$), и эффективное число независимых наблюдений о текущем $\theta(t)$ растёт как

$$n_{\text{eff}}(s) \asymp \frac{s}{\tau_E} = \lambda s \quad (\text{транзиентно, } s \lesssim \tau_{\text{conc}}). \quad (\text{S1.4})$$

Это *транзиентный* (всплесковый) режим: рост (S1.4) не продолжается до $t \rightarrow \infty$ — при $s \gtrsim \tau_{\text{conc}}$ установившийся g^* (S1.3a) обрезает накопление, и n_{eff} насыщается на флоре $n_{\text{eff}}^* = (1 - g^*)/g^* \approx 1/g^*$ (S1.3b). Линейный рост λs и насыщение на $1/g^*$ совпадают при $s \asymp \tau_{\text{conc}}$, что и фиксирует момент перехода. *Уточнение единиц времени (во избежание кажущегося двойного определения)*. Время концентрации естественно записывается в двух согласованных нормировках: (а) в *физическом* времени (число шагов s , $\Delta t = 1$) переход $n_{\text{eff}}(s) = \lambda s = n_{\text{eff}}^* = 1/g^*$ даёт $\tau_{\text{conc}}^{\text{физ}} \asymp 1/(\lambda g^*)$ — именно эта величина измеряется числом шагов до выхода фильтра на плато; (б) в *адиабатическом* времени $u = \lambda s$ (число корреляционных интервалов среды) тот же переход есть $u_{\text{conc}} = \lambda \tau_{\text{conc}}^{\text{физ}} \asymp 1/g^*$ — это форма (S1.3с), записанная в безразмерном u (равно n_{eff}^* , числу эффективных наблюдений). Связь: $\tau_{\text{conc}}^{\text{физ}} = u_{\text{conc}}/\lambda$, и обе $\propto 1/\sigma^2$ (поскольку $g^* \propto \sigma^2$). Ниже под τ_{conc} без пометки понимается физическая шкала $1/(\lambda g^*)$, кроме (S1.3с), где она берётся в адиабатическом u . Принципиально: неразделимость τ_{conc} и адиабатического потолка $1/\sigma^2$ (ключ S1.5) держится в *согласованной* нормировке — в физическом времени обе $\asymp 1/\sigma^2$, в адиабатическом обе $\asymp \lambda/\sigma^2$; отношение, на котором стоит структурная недостижимость, нормировкой не меняется. В транзиентном окне апостериорная дисперсия по «текущему уровню» латента убывает как $\Sigma_{\text{tr}}(s) \asymp 1/(\mathcal{I} n_{\text{eff}}(s)) = 1/(\mathcal{I} \lambda s)$ — стандартная байесовская концентрация $1/(\mathcal{I} n)$ с эффективным $n = \lambda s$ [5]; асимптотически $\Sigma_{\text{tr}} \rightarrow 1/(\mathcal{I} n_{\text{eff}}^*) = \Sigma_\infty$ (флор сливается со стационарным лагом).

1.3. S1.3 Квадратичное разложение мгновенной избыточной потери

Мгновенный прирост избыточной потери на шаге s — лог-отношение правдоподобий оракула и обучателя:

$$\Delta L_{\text{excess}}(s) = \ln \frac{p(X_s | \theta(s))}{\hat{p}(X_s | \hat{\theta}(s))}.$$

Усреднение по $X_s \sim p(\cdot | \theta(s))$ даёт KL-дивергенцию $D_{KL}(p(\cdot | \theta(s)) \| \hat{p}(\cdot | \hat{\theta}(s)))$. Для регулярной параметрической модели при малой ошибке слежения $\delta\theta := \hat{\theta}(s) - \theta(s)$ разложение Тейлора KL до второго порядка (первый порядок обнуляется в точке $\theta(s)$):

$$\mathbb{E}[\Delta L_{\text{excess}}(s)] = \frac{1}{2} \mathcal{I}(\theta(s)) \mathbb{E}[\delta\theta^2] + O(\mathbb{E}|\delta\theta|^3) \quad (\text{S1.5})$$

— стандартное квадратичное разложение регрета по метрике Фишера [5, 6, 2] гл. 11. Ошибка слежения $\mathbb{E}[\delta\theta^2]$ распадается на стационарную и переходную части (S1.2 и S1.4):

$$\mathbb{E}[\delta\theta^2(s)] = \underbrace{\Sigma_{\infty}}_{\text{стационарная}} + \underbrace{\Sigma_{\text{tr}}(s)}_{\text{переходная}} = \sigma_0^2(1 + O(\epsilon_{\text{track}})) + \frac{1}{\mathcal{I}\lambda s}(1 + o(1)). \quad (\text{S1.6})$$

1.4. S1.4 Интегрирование и вывод коэффициента $K/2$

Подставляя (S1.6) в (S1.5) и интегрируя по s от некоторого s_0 (после начального переходника) **на транзиентном окне концентрации** $s_0 \leq s \lesssim \tau_{\text{conc}}$, где переходная дисперсия ещё убывает по (S1.4):

$$L_{\text{excess}}^{(ij)}(t) = \int_{s_0}^t \frac{1}{2} \mathcal{I} [\Sigma_{\infty} + \Sigma_{\text{tr}}(s)] ds + \text{const} = \underbrace{\frac{1}{2} \mathcal{I} \Sigma_{\infty} (t - s_0)}_{\text{линейный } a t} + \underbrace{\frac{1}{2} \int_{s_0}^{\min(t, \tau_{\text{conc}})} \frac{ds}{s}}_{\text{логарифмический член (S1.8)}}. \quad (\text{S1.7})$$

Верхний предел логарифмического интеграла — $\min(t, \tau_{\text{conc}})$, **а не t** : подынтегральное $\Sigma_{\text{tr}}(s) \asymp 1/(\mathcal{I}\lambda s)$ справедливо лишь пока $n_{\text{eff}}(s) \asymp \lambda s$ растёт (S1.4), то есть на транзиентном окне $s \lesssim \tau_{\text{conc}}$. При $s \gtrsim \tau_{\text{conc}}$ установившийся g^* насыщает n_{eff} на флоре $1/g^*$, переходная дисперсия выходит на Σ_{∞} , и подынтегральное Σ_{tr} перестаёт давать $1/s$ -вклад — оно поглощается стационарным членом Σ_{∞} . Это и есть структурная причина транзиентности логарифма, встроенная в механизм, а не внешняя оговорка.

Точнее: переходный вклад в (S1.5) есть $\frac{1}{2} \mathcal{I} \cdot \Sigma_{\text{tr}}(s) = \frac{1}{2} \mathcal{I} \cdot \frac{1}{\mathcal{I}\lambda s} = \frac{1}{2\lambda s}$ за единицу *физического* времени (на транзиентном окне). Сведение к *адиабатическому* времени $u = \lambda s$ (число корреляционных интервалов) — содержательный шаг, опирающийся на допущение (A3) о концентрации класса II: переход к $n_{\text{eff}} \asymp \lambda s$ *мотивирован эвристически* аналогией с эффективным размером выборки

Бартлетта $n_{\text{eff}} = n/(1 + 2 \sum_s \rho(s))$ [7] для наблюдений с экспоненциальной автокорреляцией $\rho(s) = e^{-\lambda|s|}$. *Аккуратно о факторе $\frac{1}{2}$* : для $\rho(s) = e^{-\lambda|s|}$ сумма автокорреляций $1 + 2 \sum_{s \geq 1} \rho(s) \approx 2 \sum_{s \geq 0} e^{-\lambda s} \approx 2/\lambda$ при $\lambda \ll 1$, откуда $n_{\text{eff}} = n/(1 + 2 \sum_s \rho) \approx n/(2/\lambda) = (\lambda/2)n$ — то есть с фактором $\frac{1}{2}$, $n_{\text{eff}} \approx (\lambda/2)n$, а не λn . Этот фактор $\frac{1}{2}$ не исчезает бесследно: он входит лишь в *аддитивную логарифмическую константу*, не в наклон, поскольку $\ln((\lambda/2)s) = \ln(\lambda s) - \ln 2$ — сдвиг $-\ln 2$ на координату поглощается константой c_{ij} (и далее C) формулы (S1.9)–(S1.10), а коэффициент при $\ln(\lambda s)$ остаётся $\frac{1}{2}$. Поэтому записываем $n_{\text{eff}} \asymp \lambda n$ как *порядково-точное соотношение с точностью до мультипликативной константы $O(1)$* (здесь $\frac{1}{2}$), фиксирующее лишь *показатель λs* и потому наклон $K/2$; точное значение константы влияет только на C . Эта аналогия установлена Бартлеттом для оценки *среднего* стационарного коррелированного процесса; её формальный перенос на *слежение* за дрейфующим латентом строго не обоснован и вынесен в открытые вопросы (§ 7 main). Это *эвристическое сведение к классу II* [8], а не независимый вывод; строгий контроль переходного нестационарного фильтра (нестационарное уравнение Риккати) вынесен в открытые вопросы § 7 main. Сам коэффициент $\frac{1}{2}$ -на-параметр — стандартная асимптотика байесовского / MDL универсального кодирования [5, 6, 9], а его сдвинутая масштабом дрейфа predictive-information-форма — класс II [8]. С этой оговоркой плотность накопления избыточной потери на единицу u есть $\frac{1}{2}$ (по одной координате). Эквивалентно, в физическом времени, **на транзитном окне** $[s_0, \min(t, \tau_{\text{conc}})]$:

$$\int_{s_0}^{\min(t, \tau_{\text{conc}})} \frac{1}{2\lambda s} \lambda ds = \frac{1}{2} \int_{s_0}^{\min(t, \tau_{\text{conc}})} \frac{ds}{s} = \frac{1}{2} \ln \frac{\min(t, \tau_{\text{conc}})}{s_0}. \quad (\text{S1.8})$$

Два режима по соотношению t и τ_{conc} . (i) В транзитном окне $s_0 \ll t \lesssim \tau_{\text{conc}}$ интеграл даёт $\frac{1}{2} \ln(t/s_0) = \frac{1}{2} \ln(\lambda t) - \frac{1}{2} \ln(\lambda s_0)$ — логарифмический рост с коэффициентом $\frac{1}{2}$ на координату, ровно класс II [8]. Именно этот режим фиксирует аналитическое тождество $B = K/2$ (предел $\epsilon_{\text{track}} \rightarrow 0$). (ii) Асимптотически при $t \gg \tau_{\text{conc}}$ (установившийся дрейф) интеграл обрывается сверху на τ_{conc} и логарифмический член *переходит в постоянное плато*

$$\frac{1}{2} \ln \frac{\tau_{\text{conc}}}{s_0} \asymp \frac{1}{2} \ln(1/g^*) \quad (t \gg \tau_{\text{conc}}), \quad (\text{S1.8a})$$

то есть на координату — константа $\frac{1}{2} \ln(1/g^*)$, суммарно по K координатам плато высотой $\sim (K/2) \ln(1/g^*)$. Это устраняет кажущееся противоречие между $n_{\text{eff}} \asymp \lambda t \rightarrow \infty$ (S1.4) и насыщением n_{eff} флором: первое — *транзитный* всплеск концентрации ($s \lesssim \tau_{\text{conc}}$), второе — *асимптотика* установившегося дрейфа ($s \gtrsim \tau_{\text{conc}}$); они относятся к разным окнам одного интеграла, а не к двум несовместимым посылкам.

Ключевой момент — *сокращение информации Фишера*: переходная дисперсия $\Sigma_{\text{tr}}(s) = 1/(\mathcal{I}\lambda s)$ содержит $1/\mathcal{I}$, а квадратичный множитель (S1.5) содержит $\mathcal{I}$; их произведение $\frac{1}{2}\mathcal{I} \cdot 1/(\mathcal{I}\lambda s) = 1/(2\lambda s)$ не зависит от $\mathcal{I}$. Поэтому логарифмический

коэффициент определяется *только размерностью*, а не кривизной модели — это и есть универсальность класса II [8]. Собирая (S1.7)–(S1.8) для одной координаты в *транзиентном окне* $s_0 \ll t \lesssim \tau_{\text{conc}}$:

$$L_{\text{excess}}^{(ij)}(t) = a_{ij} t + \frac{1}{2} \ln(\lambda t) + c_{ij} + o(1), \quad a_{ij} = \frac{1}{2} \mathcal{I}_{ij} \Sigma_{\infty}^{(ij)} = \frac{1}{2} \mathcal{I}_{ij} \sigma_0^2 (1 + O(\epsilon_{\text{track}})). \quad (\text{S1.9})$$

Суммируя по K координатам через (S1.1):

$$L_{\text{excess}}(t) = \underbrace{\left(\sum_{ij} a_{ij} \right)}_{=:A} t + \frac{K}{2} \ln(\lambda t) + C + o(1). \quad (\text{S1.10})$$

Логарифмический коэффициент равен $\sum_{ij} \frac{1}{2} = K/2$ — тождественно, независимо от σ и от значений $\mathcal{I}_{ij}$. Линейный коэффициент $A = \sum_{ij} \frac{1}{2} \mathcal{I}_{ij} \sigma_0^2 (1 + O(\epsilon_{\text{track}})) = \frac{1}{2} \sigma_0^2 \text{tr } \mathcal{I} \cdot (1 + O(\epsilon_{\text{track}})) \propto \sigma_0^2 = \sigma^2 / (2\lambda) \rightarrow 0$ при $\epsilon \rightarrow 0$. Это доказывает транзиентную форму (3.1) *main* (на окне $1 \ll \lambda t \lesssim \lambda \tau_{\text{conc}} \asymp 1/g^*$); асимптотическую форму (3.1') *main* — линию-плюс-плато $L_{\text{excess}}(t) = At + (K/2) \ln(1/g^*) + o(t)$ при $t \gg \tau_{\text{conc}}$ — даёт обрезка логарифмического интеграла на τ_{conc} согласно (S1.8a). Обе формы — равноправные части Теоремы 1, не «асимптотика и следствие». $\square$

Следствие (3.2) main. На транзиентном окне $1 \ll \lambda t \lesssim \lambda \tau_{\text{conc}}$ (логарифмический интеграл (S1.8) обрезан сверху на $\min(t, \tau_{\text{conc}})$ согласно (S1.8a); при $t \gg \tau_{\text{conc}}$ член $(K/2) \ln(\lambda t)$ переходит в плато $(K/2) \ln(1/g^*)$ и формула (3.2) перестаёт действовать) при линейном росте бюджета $N_{\text{max}}(t) \sim Rt$ и $L_{\text{excess}}(t) \sim (K/2) \ln(\lambda t)$ (ведущий член при $A \rightarrow 0$):

$$\eta_L^{\text{excess}}(t) = \frac{L_{\text{excess}}(t)}{N_{\text{max}}(t)} \sim \frac{(K/2) \ln(\lambda t)}{Rt}, \quad \dot{\eta}_L^{\text{excess}}(t) = \frac{d}{dt} \frac{(K/2) \ln(\lambda t)}{Rt} = \frac{(K/2)}{Rt^2} - \frac{(K/2) \ln(\lambda t)}{Rt^2} \sim -\frac{K \ln(\lambda t)}{2Rt^2}$$

где в ведущем порядке $\ln(\lambda t) \gg 1$ доминирует второй член. Это (3.2) *main*. $\square$

1.5. S1.5 Конечнo-амплитудная поправка и сходимостъ $\hat{B} \rightarrow K/2$

Истинный логарифмический коэффициент равен $K/2$ (S1.10). Скан § S8.3 [1] наблюдал $\hat{B}/(K/2) = 0,54, 0,78, 0,85$ при $\epsilon = 10^{-1}, 9 \cdot 10^{-3}, 10^{-3}$ — недобор, монотонно убывающий с ϵ . Покажем, что это смещение *оценки* на конечном окне фита, а не свойство истинного коэффициента.

Совместная подгонка $L_{\text{excess}}(t) \approx \hat{A}t + \hat{B} \ln(\lambda t) + \hat{C}$ на окне $[t_{\min}, t_{\max}]$ методом наименьших квадратов оценивает $\hat{B}$ через проекцию данных на регрессор $\ln(\lambda t)$, ортогонализированный к $\{t, 1\}$. При конечном ϵ линейный член At с $A \propto \epsilon$ велик (доля дрейфа в скане: 76% при $\epsilon = 10^{-1}$), и регрессоры t и $\ln(\lambda t)$ на конечном окне $[t_{\min}, t_{\max}]$ статистически коррелированы (оба монотонно растут). Неполная ортогонализация переносит часть дисперсии логарифмического сигнала в линейный регрессор, занижая $\hat{B}$. Стандартный анализ смещения МНК при коррелированных регрессорах даёт

$$\hat{B} = \frac{K}{2}(1 - g(\epsilon, W)), \quad g(\epsilon, W) = \frac{A \cdot \text{Cov}_W(t, \ell)}{(K/2) \cdot \text{Var}_W(\ell)} \Big|_{\ell=\ln(\lambda t)} = O(\epsilon \cdot \Theta(W)), \quad (\text{S1.11})$$

где $W = t_{\max}/t_{\min}$ — отношение границ окна, $\Theta(W)$ — фактор перекрытия регрессоров (растёт с шириной окна), $A \propto \epsilon$. Поскольку $g \propto A \propto \epsilon$, имеем $g(\epsilon) \rightarrow 0$ при $\epsilon \rightarrow 0$, и $\hat{B} \rightarrow K/2$. Качественно: $\hat{B}/(K/2)$ монотонно растёт с убыванием ϵ — $0,54 \rightarrow 0,78 \rightarrow 0,85$ при $\epsilon : 10^{-1} \rightarrow 9 \cdot 10^{-3} \rightarrow 10^{-3}$ (то есть $g(\epsilon) = 0,46, 0,22, 0,15$ убывает к нулю) — что и предсказывает $g(\epsilon) \rightarrow 0$. *Точная функциональная форма $g(\epsilon)$ оставлена открытой.* Теоретическая зависимость из (S1.11) — линейная, $g \propto \epsilon^1$ (через $A \propto \epsilon$); численная же подгонка $g \approx 1,5\epsilon^{0,25}$ по трём точкам даёт показатель $\approx 0,25$, не согласующийся с теоретическим 1. Этот показатель *не выведен* и приводится лишь как грубая интерполяция по трём точкам *субоптимального* Robbins–Монро-скана § S8.3 [1] (того самого обучателя, дезавуированного ниже как «отрицательный контроль»); он *не* является законом и не должен читаться как таковой. Расхождение показателей (теория ϵ^1 против фита $\epsilon^{0,25}$) мы отмечаем как открытое — вероятно, оно отражает дополнительное $1/\sqrt{t}$ -смещение субоптимального RM-обучателя поверх коллинеарного смещения (S1.11), а не истинную форму g ; точная форма требует расширенного скана с оптимальным фильтром. Несущее утверждение S1.5 от показателя не зависит: для него достаточно монотонного $g(\epsilon) \rightarrow 0$ при $\epsilon \rightarrow 0$, что подтверждается всеми тремя точками. При $\epsilon \rightarrow 0$ (доля дрейфа $\rightarrow 0$) линейный член исчезает, регрессоры разделяются, и $\hat{B} \rightarrow K/2$ — что и есть аналитическое тождество Теоремы 1.

Отрицательный контроль § S8.3 [1]. Расширение окна до $[10^3, T_{\text{total}}]$ давало $\hat{B}/(K/2) \rightarrow 2,0$ — *завышение*. По (S1.11) расширение W увеличивает $\Theta(W)$, но при использованном обучателе Робинса–Монро с шагом $1/\sqrt{t}$ на длинных горизонтах добавляется *собственное* смещение обучателя (субоптимальность фильтра), вносящее ложный логарифмический сигнал. EWMA-фильтр с оптимальной шкалой забывания $\tau_f^{\text{forget}} \asymp \tau_E$ (ou_adiab § S4.1) устраняет именно это *завышение*: для оптимального фильтра $\Sigma(t) \rightarrow \Sigma_\infty$ без $1/\sqrt{t}$ -смещения, и расширение окна не вырождает фит вверх. Однако замена обучателя *не* привела к достижению предела $\hat{B} \rightarrow K/2$ как асимптотического наклона: расширенная проверка § S4.1 с *оптимальным* калмановским обучателем устанавливает, что логарифм реализуется лишь транзитивно, а в широком асимптотическом окне $\hat{B}/(K/2) \rightarrow 0$ (плато), так что устранение завышения подтвердилось, а сходимость к пределу — нет, и она *структурно недостижима* (см. ниже). $\square$

Согласование с прогнозом ou_adiab § S4.1 (структурная недостижимость). Расширенная проверка § S4.1 с *оптимальным* калмановским обучателем в точном линейно-гауссовом сеттинге даёт в широком асимптотическом окне ($W \approx 156$ – 166) $\hat{B}/(K/2)$ по 10 логарифмически равномерным значениям ϵ_{track} от $3 \cdot 10^{-1}$ до $3 \cdot 10^{-2}$ в пределах $[-0,31; 0,16]$ около нуля (9 из 10 bootstrap-ДИ накрывают 0, $R^2 = 1,000$): ряд плоский около 0, а не растёт к 1. Это устанавливает, что

прежняя гипотеза « $\epsilon_{\text{track}} = O(1)$, толкнуть $\epsilon_{\text{track}} \rightarrow 0$ — и $\hat{B} \rightarrow K/2$ » **неверна**. Причина двухслойна. Поверхностный слой — два механизма конечного окна, оба занижающие $\hat{B}$: (а) смещение оценки (S1.11) $g(\epsilon) > 0$ при коллинеарности t и $\ln(\lambda t)$; (б) распределение потери — хорошо настроенный фильтр с фиксированным флором Σ_∞ относит бóльшую долю потери в линейный член At . Глубинный слой — *структурный*: при OU-дрейфе логарифм класса II BNT [8] накапливается лишь пока апостериор концентрируется ($n_{\text{eff}} \sim \lambda s$, транзитный всплеск $s \lesssim \tau_{\text{conc}}$, S1.4); далее установившийся g^* ограничивает n_{eff} флором $(1 - g^*)/g^* \approx 1/g^*$ (S1.3b), L_{excess} выходит на плато высотой $\sim (K/2) \ln(1/g^*)$ (S1.8a), и в любом окне $t \gg \tau_{\text{conc}}$ логарифмического сигнала нет. Логарифмическая ширина доступного лог-несущего окна $W = t_{\text{max}}/t_{\text{min}} \asymp (1/\sigma^2)/(1/g^*) \asymp \mathcal{I}_{\text{rate}}/\lambda = 1/(\lambda r)$ **σ -инвариантна** (вывод — S1.2, «Почему окно не открывается адиабатическим пределом»): σ сокращается между нижней границей $\tau_{\text{conc}} \propto 1/\sigma^2$ и верхней (адиабатический потолок) $\propto 1/\sigma^2$, так что предел $\epsilon_{\text{track}} \rightarrow 0$ растягивает обе границы в одинаковой пропорции и окно *не открывает*. Поэтому переходное (лог-несущее, $t \lesssim \tau_{\text{conc}}$) и асимптотическое (плоское, $t \gg \tau_{\text{conc}}$) окна *не разделяются* — и это следствие *адиабатического ограничения* (фиксированной Fisher-rate на корреляционный интервал, $\mathcal{I}_{\text{rate}}/\lambda = O(1)$), а не арифметического совпадения степеней σ : расширить W можно лишь ростом $\mathcal{I}_{\text{rate}}/\lambda \rightarrow \infty$, что выводит из медленно-дрейфового режима, где верны (A1) и квазистационарность θ . Поэтому численная сходимость $\hat{B} \rightarrow K/2$ как асимптотического наклона **структурно недостижима для обучателя с насыщающейся памятью** (оптимальный стационарный фильтр). Обучателя же с *растущей* памятью, у которого n_{eff} относительно текущего $\theta(t)$ не насыщается флором, *не существует* в линейно-гауссовом окне (A1): флор $(1 - g^*)/g^*$ — *доказуемая нижняя граница* n_{eff} по всем архитектурам памяти, а не предел конкретной (см. S1.6: достаточность калмановского апостериора + MMSE + DPI), поэтому хранение всё большего числа сырых старых наблюдений не поднимает n_{eff} относительно $\theta(t)$. Декорреляция старых наблюдений (механизм Теоремы 2) — иллюстративная параллель, не несущий аргумент. Лазейка закрывается оптимальностью флора, а не ценой расширения C3 (§ S1.6; § 7 main, п. v; § 8 main, «Взаимозамкнутость»). Аналитическое тождество $B = K/2$ при этом подтверждено отдельным статическим якорем (наклон 0,990) и транзитным всплеском (0,936). Это единое объяснение, а не конкурирующие.

1.6. S1.6 Оптимальность флора как нижняя граница (достаточность калмановского апостериора и MMSE)

Тезис «флор $n_{\text{eff}}^* = (1 - g^*)/g^*$ не превышает никакой архитектурой памяти», на котором держится взаимозамкнутость маршрутов (§ 8 main) и закрытие лазейки растущей памяти в S1.5, не постулируется, а доказывается — *в линейно-гауссовом окне (A1)*. Доказательство — два стандартных факта теории фильтрации, соединённые data-processing inequality.

Факт 1 (достаточная статистика). В линейно-гауссовой модели (A1) — скрытое ОУ-состояние $\theta(t)$, гауссовы наблюдения $Y_{1:t}$ — апостериорное распределение $\theta(t) \mid Y_{1:t}$ гауссово и полностью задаётся парой $(\hat{\theta}_t, \Sigma_t)$, где $\hat{\theta}_t$ — калмановское апостериорное среднее, Σ_t — апостериорная ковариация. Эта пара есть *точная конечномерная достаточная статистика* для $\theta(t)$ при наблюдениях $Y_{1:t}$: апостериор $p(\theta(t) \mid Y_{1:t}) = p(\theta(t) \mid \hat{\theta}_t, \Sigma_t)$, и никакая иная функция $Y_{1:t}$ не несёт о $\theta(t)$ информации сверх $(\hat{\theta}_t, \Sigma_t)$ (стандартное свойство калмановского фильтра для линейно-гауссовых систем [4, 3]). Стационарная $\Sigma_\infty = \lim_t \Sigma_t$ (S1.2) — байесовски-оптимальная (MMSE) ошибка слежения за $\theta(t)$: оценка $\hat{\theta}_t$ минимизирует $\mathbb{E}[(\hat{\theta}_t - \theta(t))^2]$ по *всем* измеримым функциям $Y_{1:t}$, и стационарный фильтр Винера–Калмана–Бьюси достигает этого минимума [4] гл. 4–5. Иными словами, Σ_∞ — не свойство *конкретной* архитектуры памяти, а нижняя граница ошибки слежения по *всем* архитектурам.

Факт 2 (DPI для произвольной памяти). Пусть $S = f(Y_{1:t})$ — *любая* память (любая измеримая функция наблюдений: рекурсивная $O(1)$ -статистика, FIFO-буфер растущего размера, полный лог сырых наблюдений). По data-processing inequality

$$I(S; \theta(t)) \leq I(Y_{1:t}; \theta(t)),$$

а правая часть достигается достаточной статистикой $(\hat{\theta}_t, \Sigma_t)$ оптимального фильтра (Факт 1): $I((\hat{\theta}_t, \Sigma_t); \theta(t)) = I(Y_{1:t}; \theta(t))$. Следовательно никакая память S не несёт о $\theta(t)$ больше информации, чем калмановский апостериор, и MMSE-ошибка любой архитектуры не меньше оптимальной:

$$\mathbb{E}[(\mathbb{E}[\theta(t) \mid S] - \theta(t))^2] \geq \Sigma_\infty,$$

причём для конечного t нижняя граница есть $\Sigma_t \geq \Sigma_\infty$ (монотонное убывание апостериорной ковариации к стационарному пределу), поэтому $\geq \Sigma_\infty$ выполнено а fortiori; флор n_{eff}^* отвечает стационарному режиму $t \gg \tau_{\text{conc}}$. Для произвольной памяти $S = f(Y_{1:t})$ полагаем $n_{\text{eff}}(S) := 1/(\mathcal{I} \mathbb{E}[(\mathbb{E}[\theta(t) \mid S] - \theta(t))^2])$ — эффективное число наблюдений, определённое через *достижимую* ошибку слежения; тогда $n_{\text{eff}}(S) \leq n_{\text{eff}}^*$ есть прямое переписывание $\mathbb{E}[\cdot] \geq \Sigma_\infty$, и сравнение архитектур по n_{eff} корректно без отдельного допущения о геометрическом взвешивании (тождество $\Sigma_\infty = 1/(\mathcal{I} n_{\text{eff}}^*)$ фиксирует соответствие). Эффективное число информативных наблюдений n_{eff} настоящей работы — это число прошлых наблюдений, которое установившийся фильтр взвешивает геометрическим окном (множитель $(1 - g^*)$ за шаг), $n_{\text{eff}}^* = (1 - g^*)/g^* \approx 1/g^*$ (S1.3b): оно задаётся установившимся g^* , который, в свою очередь, есть *оптимальный* (MMSE-минимизирующий) баланс смещения и дисперсии для дрейфующего латента. Поскольку никакая память не уменьшает ошибку слежения ниже Σ_∞ , никакая архитектура не реализует *более длинного* эффективного окна усреднения относительно *текущего* $\theta(t)$, чем оптимальный фильтр: удлинение окна (большее n_{eff} , меньший g^*) при дрейфующей цели *увеличивает* лаговую ошибку и нарушает MMSE-оптимум. Поэтому флор

n_{eff}^* — максимум эффективного окна по всем архитектурам памяти, а не предел конкретной (насыщающейся) памяти; поднять n_{eff} относительно $\theta(t)$ выше него, не нарушив MMSE-границы Σ_∞ , нельзя ничем. $\square$

Область применимости и связь с C2. Доказательство конечномерности достаточной статистики опирается *существенно* на линейно-гауссовость (A1): только для линейно-гауссовой наблюдательной модели апостериор замыкается на конечномерной паре $(\hat{\theta}_t, \Sigma_t)$. Для нелинейной или не-гауссовой наблюдательной модели апостериор $p(\theta(t) \mid Y_{1:t})$ вообще *не* конечномерен (точная фильтрация требует хранения всей плотности), и MMSE-оптимальность конечномерного флора не гарантирована — этот режим открыт (§ 7 main, п. iv). В пределах (A1) аргумент строг и не опирается на декорреляцию старых наблюдений: декорреляция $\beta(\Delta t) \rightarrow 0$ (механизм Теоремы 2, C2) даёт *иллюстративную параллель* — «в старых наблюдениях нужной информации о $\theta(t)$ просто нет» — но *несущий* аргумент оптимальности флора есть достаточность + MMSE (Факты 1–2), а не декорреляция. Эти два — одно и то же следствие перемешивающей OU-структуры, прочитанное с двух сторон, но для нижней границы достаточно Фактов 1–2. Несущий объект здесь — точечный $\theta(t)$, поскольку флор n_{eff} определён через слежение за *текущим* латентом; траекторная версия (горизонт τ , условие (4.1)) нужна лишь механизму C2 и связывается с точечной для $\tau = O(1)$ (§ S2.0, Замечание «траектория versus пара»; § 8 main), но для нижней границы n_{eff} не требуется.

Что несёт качественный по-го и что — эвристика A3 (разведение несущих посылок). Подчеркнём, на чём именно стоит по-го (Утверждение 1 main), чтобы он не казался держащимся на эвристическом сведении (A3, $n_{\text{eff}} \asymp \lambda s$). *Качественный по-го* — что логарифм транзиентен, L_{excess} выходит на линию-плюс-плато, а подгоночный наклон $B \rightarrow 0$ в широком асимптотическом окне — следует уже из **конечности стационарной ошибки слежения** $\Sigma_\infty < \infty$, а это *строгий* результат алгебраического уравнения Риккати (S1.2), не эвристика. Цепочка строгая и не использует A3: $\Sigma_\infty < \infty$ (положительный корень Риккати (S1.2)) $\Rightarrow$ апостериорная дисперсия о *текущем* $\theta(t)$ ограничена снизу величиной $\Sigma_\infty > 0$ при всех t (Факты 1–2: это MMSE-оптимум, не превосходимый никакой памятью) $\Rightarrow$ эффективное число информативных наблюдений насыщается флором $n_{\text{eff}}^* = (1 - g^*)/g^* < \infty$ (тождество $\Sigma_\infty = 1/(\mathcal{I} n_{\text{eff}}^*)$) $\Rightarrow$ интеграл (S1.7)–(S1.8) логарифмического члена обрезается сверху на τ_{conc} , и логарифм транзиентен (плато (S1.8a)). Каждое звено держится на конечности Σ_∞ и оптимальности фильтра, *не* на $n_{\text{eff}} \asymp \lambda s$. Эвристика A3 нужна **только** для двух *количественных* деталей внутри транзиента: (i) значения коэффициента $K/2$ внутри логарифмического всплеска (через $n_{\text{eff}} \asymp \lambda s$ на транзиентном окне, S1.4) и (ii) точной *шкалы* $\tau_{\text{conc}} \asymp 1/g^*$. Ни транзиентность как таковая, ни существование плато, ни обнуление асимптотического наклона от A3 не зависят — они вытекают из строгого Риккати ($\Sigma_\infty < \infty$) и S1.6 (флор как MMSE-оптимум). Поэтому несущая нагрузка по-го лежит на *строгом* Риккати плюс floor-оптимуме S1.6, а эвристика A3 определяет

лишь значение $K/2$ транзистентного лога — даже если АЗ неверна количественно, по-го (транзистентность) сохраняется, меняется лишь численный коэффициент внутри всплеска.

2. S2. Доказательство Теоремы 2 (универсальность пола)

Теорема 2 main: для допустимого процесса дрейфа (условие перемешивания (4.1) main) при FIFO, $c < 1$ и per-bit-uniformity выполнено $\liminf_{t \rightarrow \infty} \nu^{\text{theor}}(t) \geq 1 - c$. Доказательство: (S2.0) общая схема через условие перемешивания; (S2.1) PSP; (S2.2) fOU с зависимостью показателя от H ; (S2.3) multi-scale; завершается проверкой, что OU — частный случай.

2.1. S2.0 Общая схема через условие перемешивания

Воспроизводим структуру [1] § 4.4, заменяя шаг «спектральная щель OU» на общее условие (4.1) main. Цепное правило для взаимной информации:

$$I(M_{\leq t}; X_E^{[t, t+\tau]}) = I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]}) + I(M_{\leq t}^{\text{stale}}; X_E^{[t, t+\tau]} \mid M_{\leq t}^{\text{refr}}). \quad (\text{S2.1})$$

Устаревшая фракция $M_{\leq t}^{\text{stale}}$ зафиксирована в момент $s \leq t - \Delta t$ как *детерминированная функция* $\theta(s)$ (запись бита в момент s). Принципиально: марковость дрейфа здесь **не** используется — аргумент опирается только на data-processing inequality для детерминированного кодирования и на стационарность приращений. Поскольку $M^{\text{stale}} = f(\theta(s))$, по DPI для первого звена

$$I(M_{\leq t}^{\text{stale}}; X_E^{[t, t+\tau]} \mid M_{\leq t}^{\text{refr}}) \leq I(\theta(s); X_E^{[t, t+\tau]} \mid M_{\leq t}^{\text{refr}}).$$

Далее $X_E^{[t, t+\tau]}$ — функция траектории $\theta_{[t, t+\tau]}$ (наблюдения порождаются текущим латентом), поэтому снова по DPI

$$I(\theta(s); X_E^{[t, t+\tau]} \mid M_{\leq t}^{\text{refr}}) \leq I(\theta(s); \theta_{[t, t+\tau]} \mid M_{\leq t}^{\text{refr}}) \leq C \cdot \beta(\Delta t), \quad (\text{S2.2})$$

где последнее неравенство — ровно условие перемешивания (4.1) main. Ни одно из двух DPI-звеньев не требует марковости: первое — детерминированность кодирования M^{stale} , второе — что наблюдения суть функция латентной траектории. Именно поэтому аргумент проходит для *не-марковского* fOU при $H > 1/2$ (приращения коррелированы на всех масштабах, спектральной щели нет) — это и есть содержательная часть § 4: достаточно перемешивания (мажоранты $\beta(\Delta t)$ для $I(\theta(s); \theta_{[t, t+\tau]})$), а не марковской декомпозиции. Это уточнение, а не опровержение [1]: марковость в Лемме 2 — *достаточное*, не необходимое условие, и Лемма 2 корректна в своём OU-классе; Теорема 2 лишь показывает, что DPI-цепь проходит и без марковости.

Замечание (траектория versus пара). Условие (4.1) main мажорирует взаимную информацию устаревшего бита с *целой будущей траекторией* латента $\theta_{[t,t+\tau]}$ на горизонте предсказания, тогда как явные $\beta(\Delta t)$, вычисляемые ниже для каждого класса (S2.3–S2.6), — это *парные* величины $I(\theta(s); \theta(t))$. Эти два объекта совпадают по показателю затухания в рассмотренных классах по двум причинам. (i) Для *марковских* OU и PSP супремум по горизонту τ не меняет показатель: по марковости $I(\theta(s); \theta_{[t,t+\tau]}) = I(\theta(s); \theta(t))$ — вся зависимость от прошлого проходит через текущее состояние $\theta(t)$, поэтому траекторная и парная мажоранты тождественны. (ii) Для *не-марковского* fOU при $H \in (1/2, 3/4)$ траекторная информация мажорируется *множественной* (блочной) корреляцией $\theta(s)$ с будущим блоком — **без** обращения к монотонности обусловливания. Строго (для $\tau = O(1)$, на котором и строится доказательство): пара «прошлый отсчёт $\theta(s)$ — будущий блок $\Theta := (\theta(t), \dots, \theta(t+\tau))$ » совместно-гауссова (fOU гауссов), поэтому взаимная информация выражается через *квадрат множественной корреляции* $R^2 := R^2(\theta(s); \Theta)$ (коэффициент детерминации линейной регрессии $\theta(s)$ на блок Θ) в замкнутой форме

$$I(\theta(s); \theta_{[t,t+\tau]}) = -\frac{1}{2} \ln(1 - R^2) = \frac{1}{2} R^2 (1 + o(1)) \quad (R^2 \rightarrow 0).$$

Здесь $R^2 = \mathbf{r}^\top \Gamma^{-1} \mathbf{r} / \sigma_0^2$, где $\mathbf{r} = (\text{Cov}(\theta(s), \theta(u)))_{u \in [t,t+\tau]}$ — вектор лаговых ковариаций, Γ — ковариационная матрица блока Θ . Это *неотрицательная квадратичная форма по $\mathbf{r}$* (так как $\Gamma^{-1} \succ 0$), и её показатель затухания по $\Delta t = t - s$ задаётся ведущей компонентой $\mathbf{r}$: при $\Delta t \gg \tau$ все $\tau + 1$ компонент $\mathbf{r}$ имеют один порядок $\sigma_0^2 \rho_H(\Delta t)$ (по (S2.4), при $H \in (1/2, 3/4)$ хвост $\rho_H \sim s^{2H-2}$ монотонно убывает на масштабе $\Delta t \gg \tau$, поэтому $|r_u| = \sigma_0^2 \rho_H(\Delta t + u) \leq \sigma_0^2 \rho_H(\Delta t)$), откуда $\|\mathbf{r}\|^2 \leq (\tau + 1) \sigma_0^4 \rho_H^2(\Delta t)$ и

$$R^2 \leq \frac{\|\mathbf{r}\|^2 \|\Gamma^{-1}\|}{\sigma_0^2} \leq C(\tau) \rho_H^2(\Delta t), \quad C(\tau) := \frac{(\tau + 1) \sigma_0^2}{\lambda_{\min}(\Gamma)} = O(1) \text{ при фикс. } \tau = O(1),$$

где $\lambda_{\min}(\Gamma) > 0$ (положительная определённость блока стационарного fOU). Следовательно $I(\theta(s); \theta_{[t,t+\tau]}) \leq \frac{1}{2} C(\tau) \rho_H^2(\Delta t) = C'(\tau) (\Delta t)^{-4(1-H)}$ — **тот же ведущий показатель** $4(1 - H)$, что и у парной $\beta(\Delta t) = \frac{1}{2} \rho_H^2(\Delta t)$ (S2.5), причём множитель $C(\tau)$ при фиксированном $\tau = O(1)$ ограничен и входит лишь в константу, не в показатель. (Спектрально-нормная мажоранта $\|\mathbf{r}\|^2 \|\Gamma^{-1}\|$ взята лишь для прозрачности константы $C(\tau)$; *точный* блочный $I(\theta(s); \Theta)$ затухает с тем же показателем $4(1 - H)$, а не быстрее — отношение $R^2 / \rho_H^2(\Delta t)$ стремится к конечной положительной постоянной, поскольку ведущая лаговая компонента $\mathbf{r}$ доминирует.) Никакого знака частных корреляций и никакого неравенства «обусловливание не увеличивает МІ» здесь *не используется*: оценка идёт прямо через множественную корреляцию совместно-гауссова блока, что корректно и для немарковского fOU (где монотонности МІ по обусловливанию нет). Для общего *растущего* τ оценка *не равномерна* по τ : $C(\tau)$ РАСТЁТ с τ — и через явный множитель $(\tau + 1)$, и через убывание $\lambda_{\min}(\Gamma)$ (которое может стремиться к нулю

при усилении внутриблочной корреляции long-memory fOU с ростом блока), так что блочная R^2 уже не мажорируется одной лаговой компонентой, и строгое утверждение не предъявляется — этот случай честно вынесен в открытые (§ 7 main, п. iv). Таким образом доказательство строится на горизонте $\tau = O(1)$ (одношаговая предсказательная информация (10) main), на котором траекторная мажоранта совпадает с парной β по показателю, а вычисленные парные β дают корректный показатель скорости.

От доли свежих битов к границе на I_{pred} (развёрнутый шаг). Переход от арифметической доли необновлённых битов к мажоранте на отношение предсказательных информаций проходит в три явных шага; раскроем его, поскольку именно здесь свёртывается per-bit-uniformity и используется корректный renewal-результат.

- (a) *Декомпозиция вклада по битам.* По per-bit-uniformity [1] Замечание 5 апостериор обучателя факторизуется по независимо обновляемым координатам (явное **ДОПУЩЕНИЕ о факторизованном апостериоре**; для fOU/PSP/multi-scale оно выполнено, так как координаты независимы по построению, см. S2.5 [и § 5 main]). *Оговорка о softmax-наблюдательной связи (параллель A1 из C1).* Per-bit-uniformity точна для факторизации латентных координат θ_{ij} (приращения dW_{ij} независимы по построению, S1.1). Но наблюдаемая $P(t)$ строится *построчным softmax*, связывающим координаты строки общей нормировкой, поэтому апостериор обучателя по наблюдениям не факторизуется *точно* — ровно та же ситуация, что в C1, где softmax-линеаризация вынесена в допущение A1. Эта связь вносит поправку порядка $O(\sigma^2/\lambda) = O(\epsilon)$ к равномерности вклада на бит (тот же tolerance-порядок, что остаток ЕКФ/Лаплас-приближения A1 в § S1, контролируемый в адиабатическом пределе $\epsilon \rightarrow 0$). Принципиально для нижней границы: поправка *не меняет знак* неравенства — коррелированный (нефакторизованный) softmax-апостериор лишь *повышает* пол ν , не пробивает его, поскольку положительная корреляция между свежими битами строки *уменьшает* их совокупный независимый предсказательный вклад относительно факторизованной оценки $N_{\text{fresh}} \cdot I_{\text{bit}}^{\text{opt}}$ (та входит как *верхняя* мажоранта в (S2.2a)–(b)). Строгий контроль этой softmax-поправки (точная неравномерность вклада на бит при связанной нормировке) — открыт (§ 7 main, п. iv); в пределах адиабатического приближения, как и A1 в C1, она поглощается в $(1+o(1))$. Поэтому суммарная предсказательная информация памяти аддитивна по битам, и каждый удержанный бит вносит вклад *равномерно* — порядка $I_{\text{bit}}^{\text{opt}} := I_{\text{pred}}^{\text{opt}}/|M_{\leq t}|$ на бит, если он свеж, и $\leq C \cdot \beta(\text{возраст})$, если устарел (по DPI-границе (S2.2)). Разбивая память на свежую (возраст $\leq \tau_E$) и устаревшую (возраст $> \tau_E$) фракции:

$$I_{\text{pred}}(t, \tau) \leq \underbrace{\sum_{\text{свежие}} I_{\text{bit}}^{\text{opt}}}_{\leq N_{\text{fresh}} \cdot I_{\text{bit}}^{\text{opt}}} + \underbrace{\sum_{\text{stale}} C \cdot \beta(\text{возраст})}_{\rightarrow 0}, \quad (\text{S2.2a})$$

где N_{fresh} — число свежих битов.

Оговорка о совместной условной МІ устаревшей фракции. Вторая сумма в (S2.2a) записана как *сумма* пер-битовых $\beta(\text{возраст})$, но величина, которую она мажорирует, есть *совместная условная* взаимная информация набора устаревших битов $I(M_{\leq t}^{\text{stale}}; X_E^{[t, t+\tau]} \mid M_{\leq t}^{\text{refr}})$; сумма пер-битовых β не мажорирует совместную без условной независимости устаревших битов, а для long-memory fOU при $H > 1/2$ её нет (приращения коррелированы на всех масштабах). Корректная мажоранта совместной условной МІ устаревшей фракции — через ту же блочную *множественную* корреляцию R^2 , что введена для траекторной мажоранты в Замечании выше (S2.2): совместная информация устаревшего блока с будущей траекторией оценивается совместно-гауссовой R^2 -формой $-\frac{1}{2} \ln(1 - R^2) = \frac{1}{2} R^2(1 + o(1))$, дающей тот же ведущий показатель $4(1 - H)$, а *не* арифметической суммой пер-битовых β . Поправка от обусловливания на $M_{\leq t}^{\text{refr}}$ (explaining-away — обусловливание может *увеличивать* МІ) — высшего порядка по ρ_H : для гауссова fOU через дополнение Шура корреляция $M_{\leq t}^{\text{refr}}$ с устаревшим $\theta(s)$ сама есть $O(\rho_H(\Delta t))$, поэтому её вклад в условную МІ устаревшей фракции мультипликативен по ρ_H и не меняет ведущий показатель $4(1 - H)$. Общий негауссов случай (где дополнение Шура неприменимо и знак explaining-away не контролируется) честно вынесен в открытые (§ 7 main, п. iv).

- (b) *Первая сумма $\leq c \cdot I_{\text{pred}}^{\text{opt}}$ через per-bit-uniformity.* Здесь нужна именно *равномерность вклада на бит* (per-bit-uniformity), а не просто аддитивность МІ, и это различие существенно. Аддитивность взаимной информации по независимым координатам (S1.1, [2] гл. 2.5) даёт лишь $I_{\text{pred}} = \sum_{\text{биты}} I_{\text{bit}}$ — она *не* запрещает свежим битам нести непропорционально большую долю $I_{\text{pred}}^{\text{opt}}$. Нам же требуется *сильнее*: что предельный вклад каждого свежего бита не превышает *среднего* $I_{\text{bit}}^{\text{opt}} = I_{\text{pred}}^{\text{opt}}/|M_{\leq t}|$. Эта равномерность обеспечивается *симметрией* независимых координат (при факторизованном апостериоре и симметричном FIFO все координаты статистически взаимозаменяемы, поэтому предельный вклад на бит одинаков и равен среднему), которую, в свою очередь, гарантирует аддитивность МІ *именно для симметричных независимых координат* (S1.1). То есть аддитивность — *необходимый ингредиент* равномерности, но не тождественна ей: per-bit-uniformity = аддитивность + симметрия координат. Поскольку при этом каждый свежий бит вносит не более $I_{\text{bit}}^{\text{opt}} = I_{\text{pred}}^{\text{opt}}/|M_{\leq t}|$, первая сумма мажорируется $N_{\text{fresh}} \cdot I_{\text{pred}}^{\text{opt}}/|M_{\leq t}| = (N_{\text{fresh}}/|M_{\leq t}|) \cdot I_{\text{pred}}^{\text{opt}}$. Доля свежих битов $N_{\text{fresh}}/|M_{\leq t}|$ есть в точности $c(1 + o(1))$ — это устанавливается в шаге (c). Тем самым $\sum_{\text{свежие}} \leq c(1 + o(1)) \cdot I_{\text{pred}}^{\text{opt}}$.

- (с) *Доля свежих битов* = c : стационарное распределение возраста FIFO-буфера. Здесь требуется не elementary renewal theorem (он про $\mathbb{E}[N(t)]/t \rightarrow 1/\mathbb{E}[\text{интервал}]$ — рост числа событий), а стационарное распределение возраста в буфере фиксированного размера при растущем притоке (backward recurrence time, [10] гл. 5). Терминологическое уточнение: для детерминированного FIFO время дожития бита постоянно (ровно $|M_{\leq t}|/\dot{M}_{\text{refresh}}$ для каждого записанного бита), поэтому распределение возрастов *равномерно без size-biasing* — классический inspection-paradox-перекоз (взвешивание длинных интервалов) возникает лишь при *случайных* длинах интервалов, а здесь интервал дожития детерминирован и одинаков, так что residual time распределён равномерно тривиально. То есть мы используем backward-recurrence-картину Кокса, но без её size-biased-компоненты — детерминированность FIFO её снимает. Для FIFO-буфера ёмкости $|M_{\leq t}|$, в который биты пишутся темпом $\dot{M}_{\text{refresh}}$, бит-снимок возраста a присутствует тогда и только тогда, когда он записан в окне $[t-a, t]$ и ещё не вытеснен; в установившемся режиме плотность возрастов равномерна на $[0, |M_{\leq t}|/\dot{M}_{\text{refresh}}]$ (каждый записанный бит «доживает» до вытеснения за время $|M_{\leq t}|/\dot{M}_{\text{refresh}}$). Доля битов возраста $\leq \tau_E$ есть тогда отношение окна свежести к полному времени дожития:

$$\frac{N_{\text{fresh}}}{|M_{\leq t}|} = \frac{\tau_E}{|M_{\leq t}|/\dot{M}_{\text{refresh}}} = \frac{\dot{M}_{\text{refresh}} \tau_E}{|M_{\leq t}|} = c, \quad (\text{S2.2b})$$

ровно определение c . Корректность доли (≤ 1) и равномерность распределения возрастов на *полном* времени дожития $|M_{\leq t}|/\dot{M}_{\text{refresh}}$ гарантированы гипотезой $c < 1$ Теоремы 2: при $c \geq 1$ было бы $\dot{M}_{\text{refresh}} \tau_E \geq |M_{\leq t}|$ (приток свежих за окно τ_E заполняет буфер целиком), доля свежих насыщается на 1, окно дожития схлопывается до τ_E , и равномерное распределение на $[0, |M_{\leq t}|/\dot{M}_{\text{refresh}}]$ перестает быть корректным; $c < 1$ как раз исключает это вырождение. (При растущем притоке это «локально-стационарное» распределение — равномерность держится на шкале $\ll |M_{\leq t}|/\dot{M}_{\text{refresh}}$, на которой приток постоянен; адиабатическое уточнение для растущего $|M_{\leq t}|$ — § S3.2.) Соответственно доля устаревших битов есть $1 - c$.

- (d) *Вторая сумма* $\rightarrow 0$. Усреднённый по равномерному распределению возрастов совокупный вклад устаревшей фракции мажорируется $\int_{\tau_E}^{\infty} C \beta(a) \frac{da}{|M_{\leq t}|/\dot{M}_{\text{refresh}}}$; при $\int_0^{\infty} \beta ds < \infty$ (т.е. $H < 3/4$ для fOU, S2.2; экспоненциальное β для OU/PSP/multi-scale) интеграл конечен, и нормировка на растущее время дожития $|M_{\leq t}|/\dot{M}_{\text{refresh}}$ обнуляет вклад с точностью $O(\beta(\tau_E)) = o(1)$ при медленном дрейфе $\beta(\tau_E) \ll 1$. Это и есть условие $\int_0^{\infty} \beta ds < \infty$, делающее DPI-мажоранту устаревшей фракции суммируемой, а не только поточечно-затухающей.

Собирая шаги (a)–(d) — (S2.2a), (S2.2b) и оценки сумм: $I_{\text{pred}}(t, \tau) \leq c(1 + o(1)) \cdot I_{\text{pred}}^{\text{opt}}(t, \tau) + o(I_{\text{pred}}^{\text{opt}})$, откуда

$$\frac{I_{\text{pred}}(t, \tau)}{I_{\text{pred}}^{\text{opt}}(t, \tau)} \leq c \cdot (1 + o(1)) \implies \nu^{\text{theor}}(t) = 1 - \frac{I_{\text{pred}}}{I_{\text{pred}}^{\text{opt}}} \geq 1 - c \cdot (1 + o(1)),$$

откуда $\liminf \nu^{\text{theor}}(t) \geq 1 - c$. Это (4.2) main. Остаётся проверить, что каждый из трёх не-OU классов удовлетворяет (4.1) main, и установить *скорость* через явный вид $\beta(\Delta t)$. $\square$ (общая схема)

2.2. S2.1 PSP (пуассоновский сброс)

PSP-логит $\theta(t)$ кусочно-постоянен; точки скачка — пуассоновский поток интенсивности $\mu = 1/\tau_E$; на каждом интервале θ независимо переразывается. Вероятность того, что между s и t не было скачка, есть $e^{-\mu(t-s)} = e^{-(t-s)/\tau_E}$; при скачке $\theta(t)$ независим от $\theta(s)$. Поэтому

$$I(\theta(s); \theta(t)) = \Pr[\text{нет скачка на } (s, t)] \cdot I(\theta \mid \text{совпадают}) = e^{-(t-s)/\tau_E} \cdot H_\theta,$$

где H_θ — энтропия маргинала стационарного распределения логита, *ограниченная константа* $C_{\text{PSP}} := H_\theta < \infty$ (маргинал PSP имеет конечную дифференциальную энтропию по построению — например, $H_\theta = \frac{1}{2} \ln(2\pi e \sigma_0^2)$ для гауссова маргинала), не зависящая от Δt . Точнее, условная взаимная информация мажорируется вероятностью отсутствия скачка:

$$\beta_{\text{PSP}}(\Delta t) = I(\theta(s); \theta(t)) \leq H_\theta \cdot e^{-\Delta t/\tau_E}. \quad (\text{S2.3})$$

Перемешивание *экспоненциальное* со шкалой $\tau_E = 1/\mu$. Условие (4.1) выполнено; $\int_0^\infty \beta_{\text{PSP}} ds = H_\theta \tau_E < \infty$. Константа пола $1 - c$ зависит от μ только через τ_E в c ; скорость приближения — экспоненциальная с той же шкалой. Чем чаще переключения (больше μ , меньше τ_E), тем быстрее декорреляция, но и тем меньше c при фиксированном $\dot{M}_{\text{refresh}}$ и $|M_{\leq t}|$, то есть тем *выше* пол $1 - c$. Это согласуется с интуицией: быстро сбрасывающаяся среда обесценивает память быстрее. $\square$

2.3. S2.2 fOU (дробный OU; зависимость показателя от H)

fOU — стационарное гауссово решение уравнения Ланжевена с дробным броуновским форсингом B^H , $H \in (0, 1)$ [11, 12]. Автокорреляция стационарного fOU при больших лагах:

$$\rho_H(s) = \mathbb{E}[\theta(t)\theta(t+s)]/\sigma_0^2 \sim \begin{cases} e^{-s/\tau_E}, & H = 1/2 \text{ (вырождение в OU)}, \\ H(2H-1)(s/\tau_E)^{2H-2}, & H > 1/2 \text{ (долгая память)}, \\ \text{экспон. с осцилляцией}, & H < 1/2 \text{ (антиперсистентность)}. \end{cases} \quad (\text{S2.4})$$

Для гауссовой пары $(\theta(s), \theta(t))$ взаимная информация $I = -\frac{1}{2} \ln(1 - \rho_H^2) = \frac{1}{2} \rho_H^2(1 + o(1))$ при $\rho_H \rightarrow 0$ ([1] § S1.5b, формула S1.5a). Подставляя (S2.4) для $H > 1/2$:

$$\beta_{\text{fOU}}(\Delta t) = \frac{1}{2} \rho_H^2(\Delta t) \sim \frac{1}{2} [H(2H - 1)]^2 (\Delta t / \tau_E)^{2(2H-2)} = C_H \cdot (\Delta t)^{-(4-4H)}, \quad (\text{S2.5})$$

— *степенное* перемешивание с показателем $4 - 4H = 4(1 - H)$. Уточнение о смене режима в точке $H = 1/2$. Показатель $4(1 - H)$ характеризует *степенной* режим $H > 1/2$; формальная подстановка $H \rightarrow 1/2$ даёт $4(1 - H) \rightarrow 2$, но это *не* предел перехода: при $H = 1/2$ автокорреляция (S2.4, первая строка) меняет класс на *экспоненциальный* ($\rho_H \sim e^{-s/\tau_E}$, а не степенной Δt^{-2}), и $\beta \sim e^{-2\Delta t/\tau_E}$ затухает быстрее любой степени. Поэтому $\Delta t^{-4(1-H)}$ при $H \rightarrow 1/2^+$ не есть предел перехода к OU, а *граница области применимости* степенной формы (S2.5): степенной и экспоненциальный режимы — разные классы затухания, разделённые точкой $H = 1/2$, а не связанные непрерывным предельным переходом по показателю. Достаточное условие (4.1) main в строгой форме требует сходимости интеграла $\int_0^\infty \beta_{\text{fOU}} ds < \infty$, то есть $4(1 - H) > 1$, или $H < 3/4$ — именно в этом диапазоне суммирование вкладов устаревших битов по равномерному распределению возрастов мажорируется сходящимся интегралом, и доказательство S2.0 проходит без оговорок. **Диапазон long-memory $H \in [3/4, 1)$ строгой Теоремой 2 не покрывается:** при $H \in [3/4, 1)$ интеграл $\int_0^\infty \beta_{\text{fOU}} ds$ расходится, и хотя поточно $\beta(\Delta t) \rightarrow 0$ (вклад каждого *фиксированного* устаревшего бита исчезает), усреднённый по возрастам совокупный вклад устаревшей фракции уже не контролируется поточечным затуханием — сумма по медленно-декоррелирующим битам может не обнуляться. Этот диапазон вынесен в открытые вопросы (§ 4.6, § 7 main): требуется отдельный аргумент (например, контроль совместной корреляционной структуры устаревшей фракции), и пол $1 - c$ для $H \in [3/4, 1)$ остаётся гипотезой, поддержанной лишь численно (fou_floor, $H = 0,9$).

Зависимость показателя скорости сноса от H . Скорость приближения ностальгии к полу:

- $H = 1/2$: экспоненциальная, $\beta \sim e^{-2\Delta t/\tau_E}$ ($\beta \approx \frac{1}{2} \rho^2$, $\rho \sim e^{-\Delta t/\tau_E}$; фактор 2 — квадрат гауссовой корреляции, потому OU-показатель $2/\tau_E$, тогда как у PSP — $1/\tau_E$ от вероятности отсутствия скачка, S2.1; восстанавливает OU [1]).
- $1/2 < H < 1$: степенная, $\beta \sim (\Delta t)^{-4(1-H)}$; чем больше H , тем меньше показатель $4(1 - H)$, тем *медленнее* устаревший бит теряет ценность, тем медленнее ностальгия выходит на пол. В пределе $H \rightarrow 1$ (граница долгой памяти) перемешивание исчезает — это граница допустимого класса.
- $H < 1/2$: антиперсистентный fOU перемешивается *быстрее* OU (осциллирующее экспоненциальное затухание); пол достигается быстрее.

Константа пола $1 - c$ во всех случаях одна и та же — она не зависит от H ,

только от $c = \dot{M}_{\text{refresh}}\tau_E/|M_{\leq t}|$. Это центральное утверждение об универсальности: показатель Хёрста управляет *темпом* сноса, но не его *глубиной*. $\square$

2.4. S2.3 Multi-scale drift

Multi-scale латент — суперпозиция $\theta(t) = \sum_{r=1}^m \theta^{(r)}(t)$ независимых OU-процессов с временами $\tau_E^{(1)} \ll \dots \ll \tau_E^{(m)}$. Автокорреляция — сумма экспонент $\rho(s) = \sum_r w_r e^{-s/\tau_E^{(r)}}$ (w_r — относительные дисперсии). При больших лагах доминирует самая медленная компонента:

$$\beta_{\text{ms}}(\Delta t) \sim \frac{1}{2} w_m^2 e^{-2\Delta t/\tau_E^{(m)}}, \quad \Delta t \gg \tau_E^{(m-1)}. \quad (\text{S2.6})$$

Перемешивание экспоненциальное со шкалой самой медленной компоненты $\tau_E^{(m)}$. Условие (4.1) выполнено; релевантная τ_E в константе c — наибольшая $\tau_E^{(m)}$ (медленнейшая компонента определяет, какие биты считаются устаревшими). Пол $1 - c$ управляется $\tau_E^{(m)}$; скорость — экспоненциальная с $\tau_E^{(m)}$. Быстрые компоненты $\tau_E^{(r)}$, $r < m$, влияют лишь на переходный режим (короткие возрасты), не на асимптотику. $\square$

2.5. S2.4 OU как частный случай и сводка

OU — это fOU при $H = 1/2$ ((S2.4), первая строка) и одновременно multi-scale с $m = 1$. Подстановка $H = 1/2$ в (S2.5) даёт экспоненциальное $\beta(\Delta t) = \frac{1}{2} e^{-2\Delta t/\tau_E}$ — ровно спектральная щель OU [1] § S1.5, формула S1.5. Префактор $\frac{1}{2}$ здесь — не отдельная константа, а ровно $\frac{1}{2}$ из гауссовой формулы взаимной информации $I = -\frac{1}{2} \ln(1 - \rho^2) = \frac{1}{2} \rho^2(1 + o(1))$ при $\rho \rightarrow 0$ (та же, что в S2.2, формула после (S2.4); $\rho = e^{-\Delta t/\tau_E}$ для OU [1] § S1.5b); квадрат корреляции $\rho^2 = e^{-2\Delta t/\tau_E}$ и даёт удвоенный показатель $2/\tau_E$. Тем самым Лемма 2 [1] § 4.4 восстанавливается как частный случай Теоремы 2, и специфика OU (спектральная щель) оказывается *достаточным*, но не необходимым условием — необходимо лишь $\beta(\Delta t) \rightarrow 0$.

Сводка управляющих параметров:

Класс	$\beta(\Delta t)$	Тип перемешивания	Шкала τ_E	Константа пола
OU ($H = 1/2$)	$e^{-2\Delta t/\tau_E}$	экспоненциальное	$1/\lambda$	$1 - c$
PSP	$e^{-\Delta t/\tau_E}$	экспоненциальное	$1/\mu$	$1 - c$
fOU ($H > 1/2$)	$(\Delta t)^{-4(1-H)}$	степенное	корр. шкала	$1 - c$
multi-scale	$e^{-2\Delta t/\tau_E^{(m)}}$	экспоненциальное	$\tau_E^{(m)}$	$1 - c$

Константа пола инвариантна по классу; показатель скорости сноса задаётся $\beta(\cdot)$. $\square$

3. S3. Доказательство Теоремы 3 (сверхлинейная память)

Теорема 3 main: при полиномиальном росте памяти $|M_{\leq t}| \propto t^\alpha$ снос насыщается ($\nu \rightarrow 1$) для любого конечного α ; побег ($\nu < 1$) требует экспоненциального роста и оплачивается расходящимся E_{grow} .

3.1. S3.1 Доля свежих битов при полиномиальном росте

Пусть $|M_{\leq t}| = M_0 t^\alpha$, $\alpha > 0$. При FIFO ностальгию управляет не полная ёмкость, а *доля битов, обновлённых за последний корреляционный интервал τ_E* . Бит считается предсказательно-полезным, если его возраст $< \tau_E$ (по S2: вклад битов старше τ_E обнуляется через перемешивание). Доля свежих битов:

$$\phi(t) = \frac{|M_{\leq t}| - |M_{\leq t-\tau_E}|}{|M_{\leq t}|} = 1 - \left(\frac{t - \tau_E}{t} \right)^\alpha. \quad (\text{S3.1})$$

При $t \gg \tau_E$ разложение $(1 - \tau_E/t)^\alpha = 1 - \alpha\tau_E/t + O((\tau_E/t)^2)$ даёт

$$\phi(t) = \frac{\alpha\tau_E}{t} (1 + O(\tau_E/t)) \sim \alpha\tau_E t^{-1} \rightarrow 0 \quad (\alpha = O(1)). \quad (\text{S3.2})$$

Для *любого* конечного α доля свежих битов убывает как t^{-1} (показатель $\gamma = 1$, не зависящий от α !). Интуиция: при полиномиальном росте приращение ёмкости за фиксированное окно τ_E есть $|M_{\leq t}| - |M_{\leq t-\tau_E}| \approx \alpha\tau_E M_0 t^{\alpha-1}$, тогда как полная ёмкость $M_0 t^\alpha$; отношение $\sim \alpha\tau_E/t \rightarrow 0$. Рост показателя α увеличивает абсолютное число свежих битов, но и полную ёмкость — в той же пропорции, так что *доля* свежего не растёт. Это решающее наблюдение: полиномиальное расширение памяти не преодолевает снос.

3.2. S3.2 Насыщение ностальгии для полиномиальной памяти

Здесь воспроизводится *поточечная* версия шага S2.0 с зависящей от времени долей свежих битов $\phi(t)$ на месте постоянного s . Подчёркнём: мы *не* ссылаемся на «обобщённую (4.2) с зависящим от времени s » как на готовый результат — DPI-мажоранта S2.0 выведена для *постоянного* s , и её перенос на растущую ёмкость требует явного адиабатического аргумента, который мы и даём.

Адиабатичность доли свежих к корреляционному окну. При FIFO и полиномиальном росте доля свежих битов есть $\phi(t) = 1 - ((t - \tau_E)/t)^\alpha$ (S3.1). Её относительная скорость изменения на масштабе одного корреляционного окна τ_E есть

$$\frac{|\phi(t) - \phi(t - \tau_E)|}{\phi(t)} = O\left(\frac{\tau_E}{t}\right) \rightarrow 0 \quad (t \gg \tau_E),$$

то есть ϕ меняется на масштабе $t \gg \tau_E$ — *адиабатически* к корреляционному окну среды τ_E (на котором происходит декорреляция и обнуление вклада

устаревших битов в S2.0). Поэтому в любом окне ширины τ_E вокруг момента t величину ϕ можно считать *локально-постоянной* с точностью $O(\tau_E/t)$.

Применение S2.0 на каждом окне с локально-постоянным $\phi(t)$. Перенос применим при $t \gg \tau_E$, где $\phi(t) < 1$ (равносильно условию $c(t) < 1$ Теоремы 2 / Леммы 2) — это выполнено автоматически при больших t , так что переход к $\liminf$ корректен. На таком окне DPI-мажоранта S2.0 (шаги (a)–(d)) применяется дословно, с заменой постоянной доли свежих s на локальное значение $\phi(t)$: per-bit-uniformity даёт аддитивность по битам, свежая фракция вносит $\leq \phi(t) I_{\text{pred}}^{\text{opt}}$, устаревшая обнуляется через $\beta(\Delta t)$ (фоновая среда удовлетворяет условию перемешивания (4.1) main, $\int \beta < \infty$; для допустимого класса § 2.6 main — для fOU $H < 3/4$, для OU/PSP/multi-scale экспоненциальное β). Поправка от непостоянства ϕ внутри окна есть $O(\tau_E/t) = o(1)$ и поглощается в $(1 + o(1))$. Тем самым *поточечно* для каждого $t \gg \tau_E$:

$$\frac{I_{\text{pred}}(t, \tau)}{I_{\text{pred}}^{\text{opt}}(t, \tau)} \leq \phi(t) \cdot (1 + o(1)) = \frac{\alpha \tau_E}{t} (1 + o(1)), \quad (\text{S3.2a})$$

откуда поточечно

$$\nu^{\text{theor}}(t) = 1 - \frac{I_{\text{pred}}}{I_{\text{pred}}^{\text{opt}}} \geq 1 - \frac{\alpha \tau_E}{t} (1 + o(1)). \quad (\text{S3.3})$$

Переход к пределу. Поскольку $\phi(t) = \alpha \tau_E/t (1 + o(1)) \rightarrow 0$, поточечная граница (S3.3) даёт $\liminf_{t \rightarrow \infty} \nu^{\text{theor}}(t) \geq 1 - \limsup_t \phi(t) (1 + o(1)) = 1$, то есть $\nu^{\text{theor}}(t) \rightarrow 1$. Снос *насыщается*: ностальгия стремится к 1, эффективность $\eta_L(t) = I_{\text{pred}}/N_{\text{max}} \rightarrow 0$. Это доказывает первую часть Теоремы 3 (насыщающийся снос при $\gamma > 0$). $\square$ (*часть 1: насыщение*)

Два канала обнуления η_L (операциональный против нормировочного). Неравенство (S3.3) — это утверждение об *отношении* $I_{\text{pred}}/I_{\text{pred}}^{\text{opt}} \rightarrow 0$ (нормировка ностальгии на оракульную норму), а не об абсолютном операциональном числителе I_{pred} . Поэтому обнуление операциональной $\eta_L = I_{\text{pred}}/N_{\text{max}}$ мы переносим не через числитель, а через *знаменатель*: $I_{\text{pred}}(t, \tau) \leq \ln k$ ограничен алфавитом, тогда как $N_{\text{max}}(t) \rightarrow \infty$ растёт неограниченно (как минимум линейно $\sim Rt$ за счёт операционной диссипации, для растущей ёмкости — степенно $\propto t^\alpha$ через E_{store} при полиномиальной памяти или экспоненциально при экспоненциальной — S3.5), откуда

$$\eta_L(t) = \frac{I_{\text{pred}}(t, \tau)}{N_{\text{max}}(t)} \leq \frac{\ln k}{N_{\text{max}}(t)} \rightarrow 0$$

операционально и безусловно, независимо от того, выходит ли I_{pred} на ненулевое плато. Это бюджетный канал; он не опирается на нормировку (S3.3) и потому надёжен операционально. Нормировочный канал — $\nu^{\text{theor}} \rightarrow 1$ — несёт интерпретацию устаревания, но его перенос на операциональную ν^{op} открыт (§ 2.2 main, направление DPI обратное; § 7 main, п. iii). Мы *не* отождествляем обнуление отношения с обнулением операционального числителя.

3.3. S3.3 Побег требует экспоненциального роста

Побег ($\liminf \nu < 1$) требует $\phi(t)$, отделинной от нуля: $\phi(t) \geq \phi_\infty > 0$ для всех больших t . По (S3.1) это означает $|M_{\leq t-\tau_E}|/|M_{\leq t}| \leq 1 - \phi_\infty < 1$, то есть ёмкость растёт *мультипликативно* на каждом интервале τ_E :

$$\frac{|M_{\leq t}|}{|M_{\leq t-\tau_E}|} \geq \frac{1}{1 - \phi_\infty} > 1 \implies |M_{\leq t}| \geq |M_0| \left(\frac{1}{1 - \phi_\infty} \right)^{t/\tau_E} = M_0 e^{\kappa t}, \quad (\text{S3.4})$$

где $\kappa = -\tau_E^{-1} \ln(1 - \phi_\infty) > 0$. Никакой полиномиальный рост не удовлетворяет (S3.4); требуется минимум экспоненциальный. В этом режиме $\phi_\infty = 1 - e^{-\kappa\tau_E}$ постоянна, и $\liminf \nu \leq 1 - c_\infty$ с $c_\infty = \phi_\infty > 0$ — побег. Тем самым критический режим — граница между полиномиальным ($\gamma = 1 > 0$, насыщение) и экспоненциальным ($\gamma = 0$, побег) ростом; собственного конечного α_c в классе полиномиальных законов нет. $\square$ (*часть 2: побег $\Rightarrow$ экспонента*)

3.4. S3.4 Термодинамическая цена побега: расходимость E_{grow}

Стоимость расширения памяти ограничена снизу ландауэровской ценой создания ёмкости $E_{\text{grow}}^{(1)} \geq k_B T \ln 2$ на бит [1] (3), § 2.4. Для экспоненциального роста (S3.4):

$$\dot{E}_{\text{grow}}(t) \geq k_B T \ln 2 \cdot \frac{d|M_{\leq t}|}{dt} = k_B T \ln 2 \cdot \kappa M_0 e^{\kappa t}, \quad E_{\text{grow}}(t) \geq k_B T \ln 2 \cdot M_0 (e^{\kappa t} - 1). \quad (\text{S3.5})$$

Оговорка обратимости. При $\kappa\tau_E = O(1)$ (режим побега, S3.4) расширение ёмкости идёт с *конечной* скоростью на корреляционном масштабе среды τ_E , то есть *не квазистатично* относительно τ_E ; поэтому обратимый (квазистатистический) предел недостижим, и ландауэровская граница $k_B T \ln 2$ на бит есть *реальная* нижняя граница, а не только асимптотическая — обратимая лазейка (создание ёмкости сколь угодно дёшево в квазистатистическом пределе) закрыта. Замечание упреждает это возражение и на сам вывод не влияет: расходимость E_{grow} и так держится через *число* создаваемых битов $\propto e^{\kappa t}$, каждый из которых стоит не менее $k_B T \ln 2$.

Несущая линия — E_{grow} ; E_{store} — усиление a fortiori. Расходимость $\eta_L \rightarrow 0$ держится уже на одном E_{grow} (через $N_{\text{max}} \geq E_{\text{grow}}/(k_B T \ln 2) \geq M_0(e^{\kappa t} - 1)$, см. (S3.6) ниже); параметр $\tau_{1/2}$ в результат *не* входит. Кумулятивная стоимость расширения растёт *экспоненциально*, что нарушает предпосылку линейного роста бюджета $N_{\text{max}}(t) \sim Rt$ (использованную в Теореме 1 и в § S8.2 [1]). К этому *a fortiori* (как усиливающая ремарка, вынесенная из несущей доказательной цепи) добавляется стоимость *хранения*: удержание $|M_{\leq t}| \propto e^{\kappa t}$ битов против эрозии даёт per-bit-мощность поддержания [1] (2)

$$\dot{E}_{\text{store}}(t) \gtrsim \frac{k_B T \ln 2}{\tau_{1/2}} \cdot |M_{\leq t}| \propto e^{\kappa t}, \quad (\text{S3.5a})$$

где $\tau_{1/2}$ — характерное время полу-эрозии бита; множитель $1/\tau_{1/2}$ восстанавливает размерность мощности (наивная запись $k_B T \ln 2 \cdot |M|$ размерно неверна — это энергия, не поток). Подчеркнём: (S3.5a) — *ослабленная* naïve-граница, в которой опущен tolerance-префактор $\ln 2/(2\varepsilon)$ точной границы поддержания [1] (2) (для целевой ошибки удержания ε). Этот префактор ≥ 1 лишь при $\varepsilon \leq \ln 2/2$; в физически релевантном диапазоне малой целевой ошибки удержания $\varepsilon \ll 1$ префактор $\ln 2/(2\varepsilon) \gg 1$, так что точная граница #2 (2) лишь *больше* naïve-границы (S3.5a), и вывод о расходимости E_{store} держится *a fortiori*. Поэтому E_{store} тоже расходится экспоненциально. Потоки E_{grow} (создание ёмкости) и E_{store} (её удержание) — физически различные работы и складываются в N_{max} без двойного счёта [1] § 2.2. Знаменатель эффективности доминируется суммой $E_{\text{grow}} + E_{\text{store}}$ (оба $\propto e^{\kappa t}$); ниже оцениваем через E_{grow} , вывод держится *a fortiori* при добавлении E_{store} :

$$N_{\text{max}}(t) \geq \frac{E_{\text{grow}}(t)}{k_B T \ln 2} \geq M_0(e^{\kappa t} - 1) \rightarrow \infty \text{ экспоненциально,}$$

тогда как числитель $I_{\text{pred}}(t, \tau) \leq \ln k$ ограничен. Поэтому

$$\eta_L(t) = \frac{I_{\text{pred}}(t, \tau)}{N_{\text{max}}(t)} \leq \frac{\ln k}{M_0(e^{\kappa t} - 1)} \rightarrow 0 \quad (\text{S3.6})$$

экспоненциально быстро — *даже при удержании ностальгии ниже 1*. Это завершает Теорему 3: снос непреодолим в сильном смысле. Полиномиальная память — насыщение ностальгии ($\nu \rightarrow 1$, числитель к нулю относительно опта); экспоненциальная память — расходимость стоимости расширения ($E_{\text{grow}} \rightarrow \infty$, знаменатель в бесконечность). В обоих случаях $\eta_L(t) \rightarrow 0$. Единственный термодинамически устойчивый ответ на снос — не побег, а периодический сброс устаревшего слоя [1] § 5.3, (12), восстанавливающий $\nu \rightarrow 0$ ценой однократной, а не экспоненциально растущей, платы. $\square$ (*часть 3: цена*)

4. S4. Детали численных симуляций

Параметры серий § 6 main. Все симуляции наследуют OU/PSP-аппарат [1] § S6, § S8.3; ниже — изменения и новые серии.

4.1. S4.1 ou_adiaб (Теорема 1)

Прямая проверка реализуемости $B = K/2$ — **в точном линейно-гауссовом (калмановском) сеттинге, в котором выводится Теорема 1** (допущение A1 здесь *точно*, а не как softmax-линеаризация), чтобы любая неудача относилась к самому BNT-логарифму, а не к субоптимальному softmax-обучателю. Модель: $K = 56$ независимых скалярных OU-координат $\theta_t = a\theta_{t-1} + w_t$ ($a = 1 - \lambda$, $\text{Var } w = q = \sigma^2$) с гауссовыми наблюдениями $y_t = \theta_t + v_t$ ($\text{Var } v = r$) и **оптимальным фильтром**

Калмана — который *и есть* идеальный байесовский обучатель Теоремы 1. Шум наблюдения r задаёт пошаговую информацию Фишера $I_{\text{rate}} = 1/r$, откуда $\epsilon_{\text{track}} = \sigma^2/(\lambda^2 r)$. Кумулятивная избыточная потеря — относительно оракула, знающего θ_t точно: пошагово по координате $0,5 \ln(S_{\text{pred}}/r) + 0,5[(y - m_{\text{pred}})^2/S_{\text{pred}} - (y - \theta)^2/r]$. $k = 8$, $\lambda = 10^{-2}$, диффузный приор $P_0 = 10^6$, 40 реализаций, зерно 20260527, bootstrap по реализациям ($N = 2000$). Три контролируемых эксперимента: **(А)** статический якорь (без дрейфа, $\lambda = 0$, $\sigma = 0$): кумулятивная избыточная потеря *обязана* быть точно $(K/2) \ln t$ (классическая MDL/BIC-избыточность [6, 5]) — проверка измерительного конвейера и целевого значения $K/2$; **(В)** диагностика *локального* лог-наклона $dL_{\text{excess}}/d \ln t$ вдоль всей траектории при ОУ-дрейфе — где именно он равен $K/2$; **(С)** скан по ϵ_{track} в **широком** асимптотическом окне $[3\tau_{\text{conc}}, 0, 1/\sigma^2]$ (нижняя граница — несколько *времён концентрации* $\tau_{\text{conc}} \asymp 1/g^* \gg \tau_E$, а не шкал забывания $\tau_f^{\text{forget}} \asymp \tau_E$; именно $3\tau_{\text{conc}}$, а не $3\tau_E$, гарантирует $t \gg \tau_{\text{conc}}$, то есть что подгонка идёт *после* транзистентного всплеска концентрации; верхняя — адиабатический потолок $\sim 1/\sigma^2 \gg \tau_{\text{conc}}$; отношение границ $W \approx 150$, не ≈ 10 ; достигается выбором $r = 10^{-2}$) с совместной подгонкой $At + B \ln(\lambda t) + C$, bootstrap-ДИ на B и диагностикой коллинеарности регрессоров $\text{corr}(t, \ln)$. Честная рамка эксперимента **(С)**: он проверяет, *персистирует* ли $(K/2) \ln$ -член как наклон в асимптотическом окне $[3\tau_{\text{conc}}, 0, 1/\sigma^2]$ — и он *не* персистирует ($B \rightarrow 0$). Это *не* «удаление транзистента, чтобы доказать его отсутствие»: сам всплеск показан отдельно в **(В)** (наклон 0,936), а **(С)** проверяет именно асимптотическую персистентность. Старт установившегося фильтра из стационарного закона в **(С)** — легитимное вычислительное сокращение: диффузный «всплеск коллапса приора» влияет лишь на аддитивную константу C , а не на асимптотический наклон B (сверено с полным транзистентным фильтром).

Параметр адиабатики (уточнение). Управляющий параметр сходимости слежения — это не сам $\epsilon = \sigma^2/\lambda$, а $\epsilon_{\text{track}} = I_{\text{rate}} \cdot \sigma^2/\lambda^2$ (§ 2 / § S1). Естественная *рабочая гипотеза* состоит в том, что прежний скан [1] § S8.3 просто не входил в режим $\epsilon_{\text{track}} \ll 1$, и достаточно «толкнуть $\epsilon_{\text{track}} \rightarrow 0$ », чтобы восстановить $\hat{B} \rightarrow K/2$ как наклон. Настоящий прогон проверяет эту гипотезу строго и **опровергает** её (см. ниже). Подчеркнём: опровергается именно эта попытка восстановить численный наклон, *не* гипотеза § S8.1 #2 [1] (функциональная форма с коэффициентом $K/2$), которую Теорема 1 аналитически подтверждает.

Фактический выход (честный — сходимость НЕ достигнута и установлено, что недостижима). **(А)** статический наклон $\text{slope}/(K/2) = 0,990$ ($R^2 = 0,99978$, целевое 1,000): BNT-логарифм *реален* в стационарной задаче без дрейфа и измерительный конвейер *корректен*. **(В)** при ОУ-дрейфе локальный лог-наклон равен $K/2$ **только в коротком начальном «всплеске коллапса приора»** (t до нескольких $1/\lambda$, где апостериор ещё концентрируется и $n_{\text{eff}} \sim t$): наклон всплеска 0,936 на $[1, 20]$; *после* всплеска (при $t \gtrsim \tau_{\text{conc}}$) установившийся g^* ограничивает эффективное число выборок флором $n_{\text{eff}} \sim (1 - g^*)/g^* \approx 1/g^*$, L_{excess} **выходит на плато** высотой $\sim (K/2) \ln(1/g^*)$, а наклон падает до 0,099 на асимптотическом

окне $[100, 0,5\tau_{\text{conc}}]$. **(С)** как следствие, в широком асимптотическом окне ($W \approx 156-166$, $n = 124$ точки на точку скана) $B/(K/2)$ **не приближается к 1** при $\epsilon_{\text{track}} \rightarrow 0$: по 10 логарифмически равномерным значениям ϵ_{track} от $3 \cdot 10^{-1}$ до $3 \cdot 10^{-2}$ оно колеблется в $[-0,31; 0,16]$ около нуля; 9 из 10 bootstrap-ДИ накрывают 0, единственное исключение ($\epsilon_{\text{track}} = 5 \cdot 10^{-2}$, $B/(K/2) = -0,31$, 95% ДИ $[-0,61; -0,02]$) лежит на *отрицательной* стороне — ещё дальше от цели $K/2$, т.е. ожидаемый при 10 независимых 95%-ДИ статистический выброс, а не сходимост; $R^2 = 1,000$ при подгонке (потеря в этом окне *строго линейна*, B садится к 0). *Контроль идентифицируемости* (в `results_summary` блок «identifiability check») подтверждает, что $B \approx 0$ — *реальное* отсутствие лог-сигнала, а не неспособность фита разделить регрессоры при их мягкой коллинеарности. Несущее свидетельство здесь — *диагностики коллинеарности и узость bootstrap-ДИ*, а не инъекционный recovery-ratio. (i) Фактор вздутия дисперсии $\text{VIF} = 1/(1 - \text{corr}^2(t, \ln)) \approx 3,7$ и число обусловленности (отношение собственных значений стандартизованного дизайна $[t, \ln]$) $\approx 12,7$ — коллинеарность *мягкая*, не вырождение, поэтому дисперсия оценки $\hat{B}$ раздута коллинеарностью лишь $\approx 3,7\times$, а не катастрофически. (ii) При этом bootstrap-ДИ на B узок относительно целевого сигнала: его полуширина $\approx 0,3 \cdot (K/2) \approx 8$ нат $\ll$ истинный лог-сигнал $K/2 \approx 28$ нат ($K = 56$) — реальный сигнал $K/2$ был бы разрешён далеко за пределами ДИ, тогда как ДИ накрывает 0. Совместно (i)+(ii) и означают, что измеренное $B \approx 0$ есть подлинное плато, а не артефакт коллинеарности. *Инъекционный тест* (внедрить во *измеренную* потерю (С) известный синтетический сигнал $B_{\text{inj}} = K/2$ и переподогнать полную модель $At + B \ln(\lambda t) + C$) даёт отношение восстановления $\Delta B/B_{\text{inj}} \approx 1,000$ — но это лишь *алгебраическое тождество линейности OLS* ($\text{coef}(y + B_{\text{inj}} \ln) = \text{coef}(y) + B_{\text{inj}} \text{coef}(\ln)$ для любого полнорангового дизайна) и потому служит только *контролем полноранговости* дизайна $[t, \ln(\lambda t), 1]$ (он не строго вырожден, $\text{corr} \neq \pm 1$); реальность плато он *не* доказывает, и формулировка «фит способен увидеть реальный лог-член» из него не следует. Рабочая гипотеза «не тот режим, толкнуть $\epsilon_{\text{track}} \rightarrow 0$ » тем самым **опровергнута**: толкание ϵ_{track} вниз не восстанавливает $B = K/2$, поскольку само окно, где живёт логарифм (переходный всплеск концентрации, $t \lesssim \tau_{\text{conc}}$), *исключается* асимптотическим требованием $t \gg \tau_{\text{conc}}$, и это исключение *структурно* — время концентрации $\tau_{\text{conc}} \asymp 1/g^*$ и адиабатический потолок (диффузионный уход латента на $O(1)$) оба масштабируются как $1/\sigma^2$, так что «переходный режим завершён» ($t \gg \tau_{\text{conc}}$) и «адиабатика ещё верна» ($t \ll 1/\sigma^2$) *не разделяются* в широкое лог-окно (отсюда и фиксированное $W \approx 1,6$ при $r = 1$; уширение до $W \approx 150$ требует малого r , но плато остаётся плоским). **Вывод**: аналитическое тождество $B = K/2$ (Теорема 1, предел $\epsilon_{\text{track}} \rightarrow 0$) реально, но реализуется *лишь транзитно*; его *численная* сжимимость как наклона в широком асимптотическом окне при подлинном ОУ-дрейфе **недостижима** для обучателя с насыщающейся памятью даже при идеальном байесовском (калмановском) фильтре (вопрос об обучателе с растущей памятью *снят*: растущая память не поднимает n_{eff} выше флора —




Рис. S1. Серия ou_adiab, эксперимент (B): локальный лог-наклон L_{excess} против t . Наклон равен $K/2$ только в коротком всплеске коллапса приора ($t \lesssim \tau_{\text{conc}}$, наклон 0,936 на $[1, 20]$); после него установившийся g^* ограничивает $n_{\text{eff}} \approx 1/g^*$, лог-компонента выходит на плато высотой $\sim (K/2) \ln(1/g^*)$, и наклон лог-члена падает до 0,099. Полная L_{excess} продолжает линейный рост $A \cdot t$ — это насыщение лог-члена, не глобальный коллапс.

флор есть доказанная нижняя граница по всем архитектурам, § S1.6; § 7 main, п. v). Это структурное ограничение C1, и оно фиксируется как таковое (§ 7 main). Результаты — `results_summary.{txt,json}`. Плоский скан $B/(K/2) \approx 0$ против якоря и всплеска показан на рис. 1 основного текста.

4.2. S4.2 fou_floor (Теорема 2, степенной конец)

Реальная траекторная симуляция на точном стационарном fOU (а не пересчёт замкнутой формулы β_H и не суррогат). $K = 56$ независимых стационарных fOU-траекторий логитов генерируются **спектрально-циркулянтным методом** напрямую из спектральной плотности стационарного fOU $S(\omega) \propto |\omega|^{1-2H}/(\lambda^2 + \omega^2)$ (приращения fBm дают $|\omega|^{1-2H}$, OU-фильтр $1/(\lambda + i\omega) - 1/(\lambda^2 + \omega^2)$; $\lambda = 1/\tau_E$) для $H \in \{0,3,0,5,0,7,0,9\}$. Собственные значения циркулянта Davies–Harte суть

эта дискретно-временная плотность на сетке $\omega_j = 2\pi j/M$ (Винер–Хинчин), построенная как свёрнутый (folded) спектр на $(-\pi, \pi]$ с бин-усреднением интегрируемой особенности при $\omega = 0$ для $H > 1/2$, — **неотрицательная по построению**, так что вложение положительно определено с *нулевым обрезанием* (фактически $\min$ с.з. = 0,43; 0,24; 0,14; 0,086 и ноль отрицательных при $H = 0,3; 0,5; 0,7; 0,9$; инфраструктурный сбой циркулянта не возникает). Целевая автоковариация $\gamma(k)$ — точное обратное ДПФ собственных значений (та же ковариация, по которой синтезируются пути), точна до лага $M/2$; показатель читается до лага $M/4$. $\tau_E = 200$ и M_{refresh} фиксированы так, что $c \approx 0,3$; $|M| = 400$, $T = 2 \cdot 10^4$, длина пути $3,3 \cdot 10^4$, циркулянт $M = 6,6 \cdot 10^4$, 40 реализаций, зерно 20260527, только `numpy.fft` (без `scipy`). **Контроль ковариации:** эмпирическая лаг-корреляция реализованных путей $\hat{\rho}(s)$ совпадает с $\gamma(s)$ там, где конечновыборочный оценщик ACF несмещён (ближние/средние лаги, отн. ошибка $< 5\%$ до лага ~ 200 –400); на больших лагах сам оценщик ACF на долгой памяти сильно смещён к нулю — поэтому дальний хвост читается по точной γ , которую пути воплощают по построению, а не по выборочной ACF. FIFO-память хранит снимки $\theta(t_{\text{write}})$; бит предсказателен, пока $\hat{\rho}^2(\text{возраст}) \geq \hat{\rho}^2(\tau_E)$ (пороговая DPI-модель горизонта). *Фактический выход:* $\liminf \nu = 0,700 \approx 0,70$ для всех H , разброс 0,000 (инвариантность воспроизводится на корректных fOU-путях). Пол при этом **заложен в пороговую модель** — задаётся долей свежих битов c через горизонт $\hat{\rho}^2(\tau_E)$: симуляция иллюстрирует инвариантность на реальных траекториях, но не доказывает её (доказательство — § S2; § S4.5). **Показатель скорости подтверждает $4(1-H)$ на корректном процессе, в дальнем хвосте.** Он измеряется по точной ковариации $\rho^2(\Delta) = 2\beta(\Delta) = \gamma^2(\Delta)$ (без подгонки под целевой) в дальних окнах $[8, 40]_{\tau_E}$ и $[20, 80]_{\tau_E}$, где степенной хвост проявляется за OU-«коленом». Два значения H имеют разный доказательный статус: $H = 0,7$ — диапазон $H < 3/4$ ($\int \beta < \infty$, S2.2), *внутри* строгой Теоремы 2, поэтому показатель 1,237 и 1,201 (аналитика 1,2) есть *внутритеоремное подтверждение*; $H = 0,9$ — диапазон $H \geq 3/4$ ($\int \beta$ расходится), *вне* строгой теоремы, поэтому показатель 0,406 и 0,385 (аналитика 0,4) есть лишь *численно поддерживаемая гипотеза*, а не доказательство строгого результата на непокрытом диапазоне. В исходном ближнем окне $[\tau_E, 8\tau_E]$ показатель *не* изолируется: 1,62 ($H = 0,7$) и 0,46 ($H = 0,9$) по точной ковариации (OU-колено), 2,44 и 1,40 по конечновыборочному оценщику ACF (смещение оценщика на больших лагах). Тем самым $\Delta^{-(4-4H)}$ (S2.5) — *асимптотический дальне-хвостовой* показатель истинного fOU: восстанавливается на корректном процессе в дальнем окне, но не в наименьшем и не из выборочной ACF. **Это апгрейд C2:** в отличие от наивного суррогата AR(1)ofGn (давшим 2,23 и 1,26 вне ДИ от $4(1-H)$ — *свойство суррогата, не теории*), на корректном стационарном fOU воспроизводятся и *глубина* пола $(1-c)$ (Теорема 2), и *показатель* $4(1-H)$. Качественная дихотомия держится: при $H = 0,5$ хвост экспоненциальный (скорость $4,07 \cdot 10^{-3}$ /шаг, OU-контроль § 6.2 [1]), при $H > 0,5$ — степенной с показателем $4(1-H)$. $H = 0,9$ — диапазон $H \geq 3/4$, не покрытый строгой Теоремой 2 (§ S2.2), численно поддерживаемая гипотеза; там сходимость к




Рис. S2. Серия `fou_floor`, инвариантность глубины пола по H (by-construction; лог-ось t). Ностальгическая доля $\nu(t)$ равна нулю, пока буфер моложе горизонта корреляции $\tau_E = 200$ (ни один бит ещё не старше τ_E), затем выходит на пол $1 - c = 0,700$, одинаковый для всех $H \in \{0,3; 0,5; 0,7; 0,9\}$ — кривые совпадают (инвариантность глубины). Пол здесь *зашит* пороговой моделью (доля свежих = c через горизонт $\rho^2(\tau_E)$): иллюстрация инвариантности на корректных fOU-путях, а не независимое измерение — независимую оценку глубины несёт реализованный PSP-поток (рис. 2 основного текста).

$4(1 - H)$ медленнее (0,385 на $[20, 80]\tau_E$ чуть ниже 0,4).

4.3. S4.3 `psp_floor` (Теорема 2, экспоненциальный конец)

Реальная траекторная симуляция PSP-суррогата [1] § 6.1 (а не пересчёт $e^{-\mu\Delta}$): $k = 8$, $K = 56$; каждая координата несёт *реализованный* пуассоновский поток сбросов интенсивности $\mu \in \{10^{-3}, 3 \cdot 10^{-3}, 10^{-2}\}$ (пошаговая вероятность сброса $1 - e^{-\mu}$). $|M| = 400$ подобрано под $c \approx 0,3$ для каждого μ ($\tau_E = 1/\mu$); $T = 2 \cdot 10^4$, 40 реализаций, зерно 20260528. FIFO-память хранит снимки с меткой координаты; удержанный бит остаётся предсказательным, пока его координата *фактически* не сбросилась с момента записи, и становится ностальгическим в шаг сброса. Пол и скорость декорреляции читаются из реализованного процесса. Скорость оценивается по эмпирической кривой выживания $\hat{S}(\text{возраст})$ (доля удержанных битов данного возраста, ещё не увидевших сброс): фит $\ln \hat{S} \sim -\text{rate} \cdot \text{возраст}$ на $[0, \min(5\tau_E, |M|/\dot{M}_{\text{refresh}})] \approx [0, 3, 3\tau_E]$ (биты вытесняются FIFO на возрасте $|M|/\dot{M}_{\text{refresh}} = \tau_E/c \approx 3,3\tau_E$) в полулогарифмических координатах, с bootstrap-ДИ по реализациям; равенство скорости μ не постулируется. *Фактический выход*: установившийся эмпирический пол $\hat{\nu}_{\text{floor}} = 0,709\text{--}0,713 \approx 1 - c = 0,70$ на 10-кратном диапазоне μ (разброс 0,004) — инвариантность к μ подтверждена;




Рис. S3. Серия `fou_floor`, контроль ковариации. Эмпирическая лаг-корреляция реализованных путей $\hat{\rho}(s)$ против целевой $\gamma(s)$: совпадение (отн. ошибка $< 5\%$) до лага $\sim 200\text{--}400$, где конечновыборочный оценщик ACF несмещён; на больших лагах сам оценщик ACF на долгой памяти смещён к нулю — поэтому дальний хвост показателя читается по точной γ , которую пути воплощают по построению, а не по выборочной ACF. Подтверждает, что генерируется подлинный стационарный fOU.




Рис. S4. Серия `fou_floor`, выход на пол и показатель скорости. Хвост $\rho^2(\Delta) = 2\beta(\Delta)$ по точной ковариации для $H \in \{0,3; 0,5; 0,7; 0,9\}$; дальне-хвостовой лог-лог-наклон совпадает с аналитическим $4(1 - H)$ (внутритеоремно при $H = 0,7: 1,24/1,20$; численно поддерживаемая гипотеза при $H = 0,9: 0,41/0,39$). При $H = 0,5$ хвост экспоненциальный (OU-контроль). Показатель — *асимптотический дальне-хвостовой*: за OU-«коленом», не в наименьшем окне.




Рис. S5. Серия `psp_floor`, реализованная кривая выживания $\hat{S}$ (возраст) (доля удержанных битов данного возраста, ещё не увидевших сброс) в полулогарифмических координатах. Наклон даёт скорость декорреляции $1,01 \cdot 10^{-3}$, $3,01 \cdot 10^{-3}$, $1,00 \cdot 10^{-2}$; каждый bootstrap-ДИ накрывает номинальный $\mu = 1/\tau_E$ — настоящее измерение шкалы $1/\mu$ из реализованного процесса (равенство μ не постулируется).

поскольку процесс реализованный, установившийся пол чуть *выше* 0,70 (значение пола не зашито в порог). Покадровая нижняя огибающая (колонка `liminf` в `results_summary`) опускается до $\approx 0,69$ из-за конечно-выборочного шума по 40 реализациям, но *медианный установившийся* уровень $\hat{\nu}_{\text{floor}}$ — выше $1 - c$; для инвариантности глубины пола релевантен установившийся уровень. Реализованная скорость декорреляции равна $1,01 \cdot 10^{-3}$, $3,01 \cdot 10^{-3}$, $1,00 \cdot 10^{-2}$, и каждый bootstrap-ДИ *накрывает* номинальный $\mu = 1/\tau_E$ (S2.3) — настоящее измерение шкалы $1/\mu$. Расхождений с теорией нет: экспоненциальная скорость μ подтверждена здесь, степенной показатель $4(1 - H)$ — в `fou_floor` (на корректном стационарном fOU, дальний хвост, § S4.2). Инвариантность установившегося пола к частоте сбросов μ (несущее независимое свидетельство глубины C2) показана на рис. 2 основного текста.

4.4. S4.4 *superlinear_memory* (Теорема 3)

Память $|M_{\leq t}| = M_0 t^\alpha$, $\alpha \in \{1, 1,5, 2, 3\}$, плюс экспоненциальная $|M_{\leq t}| = M_0 e^{\kappa t}$ с $\kappa \tau_E \in \{0, 1, 0,5, 1\}$. ОУ-дрейф фоновой среды, $\tau_E = 200$, FIFO-refresh, зерно 20260529. Измеряется $\nu(t)$, доля свежих битов $\phi(t)$ (S3.1), и для экспоненциального случая — кумулятивная $E_{\text{grow}}(t)$ и $\eta_L(t)$. *Фактический выход*: для всех полиномиальных α — $\phi(t) \sim t^{-\gamma}$ с $\gamma \in \{1,000; 0,991; 0,982; 0,964\}$ (разброс 0,036, $\gamma \approx 1$ независимо от α), префактор $\phi \cdot t \rightarrow \alpha \tau_E$ (200, 298, 394, 581 про-




Рис. S6. Серия `superlinear_memory`, экспоненциальный побег и его цена. При $|M_{\leq t}| = M_0 e^{\kappa t}$ доля свежих выходит на ненулевой предел $\varphi_\infty = 1 - e^{-\kappa \tau_E} \in \{0,095; 0,394; 0,632\}$ (побег: $\nu < 1$), но кумулятивная стоимость расширения ёмкости $E_{\text{grow}}(t) \propto e^{\kappa t}$ расходится (отношение до $9,8 \cdot 10^{42}$), и эффективность $\eta_L(t) \rightarrow 0$ через знаменатель. Побег формально удерживает ностальгию ниже 1, но термодинамически разорителен.

тив 200, 300, 400, 600), $\nu(t) \rightarrow 1$ (S3.2–S3.3) — подтверждение отсутствия полиномиального α_c ; малое отклонение γ от 1 при больших α — конечно-оконный subleading-артефакт, ведущий показатель тождественно 1. *Диагностика сходимости окна* (`gamma_window_convergence` в `results_summary`; детерминированная табуляция точного $\phi = 1 - ((t - \tau_E)/t)^\alpha$, не Монте-Карло): при скольжении окна фита (декада $[w, 10w]$) вправо показатель γ монотонно растёт к 1 для *каждого* α — при подъёме окна на порядок ($w = 2 \cdot 10^4$) $\gamma \rightarrow \{1,000; 0,999; 0,998; 0,996\}$, при $\times 1000$ ($w = 2 \cdot 10^6$) $\gamma \rightarrow \{1,000; 1,000; 1,000; 1,000\}$ при $\alpha \in \{1; 1,5; 2; 3\}$; локальный лог-лог-наклон ϕ садится к -1 ($-0,897 \rightarrow -0,990 \rightarrow -0,999 \rightarrow \dots \rightarrow -1,000$ при $t = 2 \cdot 10^3 \dots 2 \cdot 10^9$). Тем самым дрейф γ вниз на baseline-окне — subleading-кривизна конечного окна, а не зависимость ведущего показателя от α ; ведущий показатель тождественно 1, и полиномиального α_c нет. Для экспоненциального роста — $\phi_\infty = 1 - e^{-\kappa \tau_E} \in \{0,095; 0,394; 0,632\} > 0$, $\nu(t) < 1$, но $E_{\text{grow}}(t) \propto e^{\kappa t}$ расходится (отношение до $9,8 \cdot 10^{42}$ за прогон) и $\eta_L(t) \rightarrow 0$ через знаменатель (S3.5–S3.6). Насыщение $\phi(t) \rightarrow 0$ при полиномиальном росте (отсутствие α_c) показано на рис. 3 основного текста.

4.5. S4.5 Общие конвенции и ограничения

Во всех сериях истинное $\theta(t)$ известно по построению, поэтому $\nu^{\text{theor}} = \nu^{\text{op}}$ [1] § 6; используется $\nu(t)$ без индекса. *Оговорка об оценщике.* В численных сериях #3 (`fou_floor`, `psp_floor`) ностальгия $\nu(t)$ читается не KSG-оценщиком взаимной информации, а из *пороговой DPI-модели горизонта*: бит возраста Δ считается полезным, если его предсказательная ценность по реализованной автокорреляции $\hat{\rho}^2(\Delta)$ (survival на известном $\theta(t)$) превышает DPI-порог $\rho^2(\tau_E)$, иначе — ностальгическим. Поскольку $\theta(t)$ известно по построению, обусловливание

на латент реализуется *фиксацией* истинного θ , и условная $I_{\text{pred}} = I(X_t; X_{t+\tau} \mid \theta(t))$ измеряется напрямую — отсюда $\nu^{\text{theor}} = \nu^{\text{op}}$ by construction; отдельный СМІ-оценщик не требуется. Упоминание KSG [1] § S6 наследуется от сопровождающей работы #2 и к численным сериям #3 *не применяется* (там θ известно по построению). Симуляции иллюстрируют, но не доказывают теоремы (§ S1–S3 несут доказательства); не выходят за пределы абстрактных марковских цепей; не покрывают не-перемешивающийся (heavy-tailed) класс вне области Теоремы 2. Полная реализация, зёрна, псевдокод и регенерация рисунков — в `simulations/{ou_adiab,fou_floor,psp_floor,superlinear_memory}/README.md` репозитория-зеркала `andriishin/landauer-undertow-oa`.

References

- [1] Andriishin A 2026 The non-stationary Landauer efficiency: memory growth, informational nostalgia, and the thermodynamics of learning systems Companion paper #2; preprint deposited on Zenodo (frozen version v1) public open-access mirror: <https://github.com/andriishin/landauer-nostalgia-oa>.
- [2] Cover T M and Thomas J A 2006 *Elements of Information Theory* 2nd ed (Hoboken, NJ: Wiley-Interscience)
- [3] Kalman R E and Bucy R S 1961 *J. Basic Eng.* **83** 95–108
- [4] Anderson B D O and Moore J B 1979 *Optimal Filtering* (Englewood Cliffs, NJ: Prentice-Hall)
- [5] Clarke B S and Barron A R 1990 *IEEE Trans. Inf. Theory* **36** 453–471
- [6] Rissanen J 1986 *Ann. Statist.* **14** 1080–1100
- [7] Bartlett M S 1946 *Suppl. J. R. Stat. Soc.* **8** 27–41
- [8] Bialek W, Nemenman I and Tishby N 2001 *Neural Comput.* **13** 2409–2463
- [9] Schwarz G 1978 *Annals of Statistics* **6** 461–464
- [10] Cox D R 1962 *Renewal Theory* (London: Methuen)
- [11] Mandelbrot B B and Van Ness J W 1968 *SIAM Rev.* **10** 422–437
- [12] Cheridito P, Kawaguchi H and Maejima M 2003 *Electron. J. Probab.* **8** 1–14